Teoria da Credibilidade — Laboratório 2, Parte 1 (2026/1)

</> Mostrar/ocultar todos os códigos ▾

Previsão de Mortalidade em Fundo de Pensão via Bühlmann-Straub

AUTOR
Arthur Pontes Motta e Catarine Martins

DATA DE PUBLICAÇÃO
16 de junho de 2026

Sumário

Leitura dos dados
Questão (i): Análise Exploratória
Questão (ii): Perfil Etário e Faixas de Risco
Questão (iii): Seleção de Tábuas de Referência
Questão (iv): Definição dos Perfis de Risco
Questão (v): Modelo de Bühlmann-Straub — Frequência de Sinistros
Questão (vi): Modelo Hierárquico Bayesiano — Poisson com Efeitos Aleatórios (Stan)
Informações da Sessão
Referências

Os dados referem-se a um fundo de pensão brasileiro do tipo **Entidade Fechada de Previdência Complementar (EFPC)**, com registros de expostos e óbitos por idade para os anos de 2012, 2013 e 2014. As EFPCs são fundações sem fins lucrativos vinculadas a empresas patrocinadoras; os participantes acumulam reservas para aposentadoria complementar e o plano cobre ainda o risco de morte do segurado, cujo benefício é repassado aos beneficiários indicados (ABRAPP, 2022). A supervisão é exercida pela Superintendência Nacional de Previdência Complementar (PREVIC).

O objetivo desta parte é obter o **número esperado de sinistros por classe de risco para o próximo ano** com base no modelo de Bühlmann-Straub para a frequência de sinistros, seguindo o desenvolvimento de Bühlmann; Gisler (2005). O caminho percorrido é: (i) análise exploratória; (ii) perfis etários e faixas de risco; (iii) seleção e avaliação formal de tábuas de referência; (iv) definição dos grupos; (v) implementação do modelo e previsão.

Leitura dos dados

▼ Ocultar código

```r
fundo <- read.csv("dadosfundopensao.csv", header = TRUE, sep = ";")
cat("Dimensão:", paste(dim(fundo), collapse = " x "), "\n")
```

```
Dimensão: 116 x 7
```

▼ Ocultar código

```r
fundo |> head(8) |>
  gt() |>
  tab_header(title = "Primeiras linhas — dados do fundo de pensão") |>
  tab_options(table.font.size = 13)
```

Primeiras linhas — dados do fundo de pensão

idade	EXP2012	OBT2012	EXP2013	OBT2013	EXP2014	OBT2014
0	0	0	0	0	0	0
1	1	0	0	0	0	0
2	3	0	1	0	0	0
3	3	0	3	0	1	0
4	0	0	3	0	4	0
5	4	0	0	0	3	0
6	2	0	5	0	0	0
7	2	0	2	0	6	0

▼ Ocultar código

```r
fundo_long <- tibble(
  Idade     = rep(fundo$idade, 3),
  Expostos = c(fundo$EXP2012, fundo$EXP2013, fundo$EXP2014),
  Obitos   = c(fundo$OBT2012, fundo$OBT2013, fundo$OBT2014),
  Ano      = rep(c("2012","2013","2014"), each = nrow(fundo))
) |>
  mutate(
    tx     = if_else(Expostos > 0, Obitos / Expostos, NA_real_),
    log_tx = if_else(tx > 0, log(tx), NA_real_)
  )

sum_d2 <- fundo_long |>
  group_by(Idade) |>
  summarise(tot_obt = sum(Obitos), tot_exp = sum(Expostos), .groups = "drop")

# ── Métricas para uso em texto inline ────────────────────────────────────────
resumo_anual <- fundo_long |>
  group_by(Ano) |>
  summarise(
    Expostos          = sum(Expostos),
    Obitos            = sum(Obitos),
    taxa_bruta_mil    = round(1000 * sum(Obitos) / sum(Expostos), 1),
    .groups = "drop"
  )

tot_exp_tri  <- sum(sum_d2$tot_exp)
tot_obt_tri  <- sum(sum_d2$tot_obt)
n_idades     <- nrow(sum_d2)
taxa_2012    <- resumo_anual$taxa_bruta_mil[resumo_anual$Ano == "2012"]
taxa_2014    <- resumo_anual$taxa_bruta_mil[resumo_anual$Ano == "2014"]
cresc_taxa   <- round((taxa_2014 - taxa_2012) / taxa_2012 * 100, 1)
exp_2012     <- resumo_anual$Expostos[resumo_anual$Ano == "2012"]
exp_2014     <- resumo_anual$Expostos[resumo_anual$Ano == "2014"]
```

```
cresc_exp    <- round((exp_2014 - exp_2012) / exp_2012 * 100, 1)

resumo_anual |>
  select(Ano, Expostos, Obitos, `Taxa bruta (‰)` = taxa_bruta_mil) |>
  gt() |>
  tab_header(title = "Resumo anual da carteira") |>
  fmt_number(columns = c(Expostos, Obitos), decimals = 0) |>
  tab_options(table.font.size = 13)
```

Resumo anual da carteira

Ano	Expostos	Obitos	Taxa bruta (‰)
2012	137,797	1,131	8.2
2013	138,919	1,192	8.6
2014	141,248	1,335	9.5

A base cobre 116 idades (0 a 115) ao longo de $T = 3$ anos, totalizando 417.964 pessoas-ano de exposição e 3.658 óbitos. A taxa bruta passou de 8.2‰ em 2012 para 9.5‰ em 2014, crescimento de 15.9% com exposição praticamente estável (+2.5%), revelando envelhecimento progressivo da carteira. Vale registrar que a Portaria PREVIC nº 835/2020 (PREVIC, 2020) exige, para adequação da tábua de mortalidade geral, no mínimo **cinco exercícios** — horizonte não atingido com esses dados, limitação que deve ser declarada explicitamente e que reforça a escolha do modelo de credibilidade como alternativa robusta para períodos curtos.

Questão (i): Análise Exploratória

Caracterização da massa e métricas de maturidade

▼ Ocultar código

```
# Idade média ponderada pela exposição (triênio)
idade_media <- with(sum_d2, sum(Idade * tot_exp) / sum(tot_exp))

# Exposição e óbitos acima de 60 anos
pct_obt_60p <- sum(sum_d2$tot_obt[sum_d2$Idade >= 60]) / sum(sum_d2$tot_obt)
pct_exp_60p <- sum(sum_d2$tot_exp[sum_d2$Idade >= 60]) / sum(sum_d2$tot_exp)

# Índice de dependência (expostos 60+ / expostos 18-59)
dep_idx <- sum(sum_d2$tot_exp[sum_d2$Idade >= 60]) /
           sum(sum_d2$tot_exp[sum_d2$Idade >= 18 & sum_d2$Idade < 60])

# Variáveis para uso inline
idade_media_r  <- round(idade_media, 1)
dep_idx_r      <- round(dep_idx, 3)
pct_obt_60p_r  <- round(pct_obt_60p * 100, 1)
pct_exp_60p_r  <- round(pct_exp_60p * 100, 1)

tibble(
  Métrica = c(
    "Exposição total (pessoas-ano)",
    "Óbitos totais",
    "Idade média ponderada pela exposição",
    "Taxa bruta média 2012--2014 (‰)",
    "% óbitos acima de 60 anos",
    "% expostos acima de 60 anos",
    "Índice de dependência (60+)/(18--59)"
  ),
  Valor = c(
    sum(sum_d2$tot_exp),
    sum(sum_d2$tot_obt),
    idade_media_r,
    round(1000 * sum(sum_d2$tot_obt) / sum(sum_d2$tot_exp), 3),
    pct_obt_60p_r,
    pct_exp_60p_r,
    dep_idx_r
  )
) |>
  gt() |>
  tab_header(title = "Métricas de caracterização da carteira (triênio 2012--2014)") |>
  tab_options(table.font.size = 13)
```

Métricas de caracterização da carteira (triênio 2012--2014)

Métrica	Valor
Exposição total (pessoas-ano)	417964.000
Óbitos totais	3658.000
Idade média ponderada pela exposição	45.200
Taxa bruta média 2012--2014 (‰)	8.752
% óbitos acima de 60 anos	89.700
% expostos acima de 60 anos	26.400
Índice de dependência (60+)/(18--59)	0.359

A idade média ponderada de ≈ 45.2 anos e o índice de dependência de ≈ 0.359 apontam para um plano em maturidade intermediária: a massa ainda é predominantemente ativa, mas o peso dos assistidos nas idades avançadas já responde por 89.7% dos óbitos. Planos com índice de dependência acima de $0,5$ são considerados demograficamente maduros (Pitacco et al., 2009); este fundo está em trajetória ascendente, o que implica crescimento estrutural da sinistralidade mesmo sem piora intrínseca das taxas de mortalidade.

Pirâmide etária da exposição

▼ Ocultar código

```r
intervalos <- c(0, 18, 40, 60, 80, 116)
labels_fx  <- c("[0, 18)", "[18, 40)", "[40, 60)", "[60, 80)", "80+")

sum_d2 <- sum_d2 |>
  mutate(faixa = cut(Idade, breaks = intervalos, right = FALSE, labels = labels_fx))

piramide <- sum_d2 |>
  group_by(faixa) |>
  summarise(
    Expostos = sum(tot_exp),
    Obitos   = sum(tot_obt),
    .groups  = "drop"
  ) |>
  mutate(pct_exp = Expostos / sum(Expostos) * 100,
         pct_obt = Obitos   / sum(Obitos)   * 100)

# Variáveis inline para o parágrafo
pct_exp_1840_4060 <- round(sum(piramide$pct_exp[piramide$faixa %in% c("[18, 40)", "[40, 60)")]),
pct_obt_1840_4060 <- round(sum(piramide$pct_obt[piramide$faixa %in% c("[18, 40)", "[40, 60)")]),
pct_exp_6080_80p  <- round(sum(piramide$pct_exp[piramide$faixa %in% c("[60, 80)", "80+")]), 1)
pct_obt_6080_80p  <- round(sum(piramide$pct_obt[piramide$faixa %in% c("[60, 80)", "80+")]), 1)

p_exp <- ggplot(piramide, aes(x = faixa, y = pct_exp, fill = faixa)) +
  geom_col(alpha = 0.85, width = 0.7) +
  geom_text(aes(label = sprintf("%.1f%%", pct_exp)), hjust = -0.1, size = 3.2) +
  coord_flip() +
  scale_y_continuous(limits = c(0, 52), labels = label_percent(scale = 1)) +
  labs(x = NULL, y = "% Expostos") +
  theme_bw(base_size = 11) + theme(legend.position = "none")

p_obt <- ggplot(piramide, aes(x = faixa, y = pct_obt, fill = faixa)) +
  geom_col(alpha = 0.85, width = 0.7) +
  geom_text(aes(label = sprintf("%.1f%%", pct_obt)), hjust = -0.1, size = 3.2) +
  coord_flip() +
  scale_y_continuous(limits = c(0, 55), labels = label_percent(scale = 1)) +
  labs(x = NULL, y = "% Óbitos") +
  theme_bw(base_size = 11) + theme(legend.position = "none",
                                   axis.text.y = element_blank(),
                                   axis.ticks.y = element_blank())

p_exp + p_obt +
  plot_annotation(title = "Distribuição relativa de expostos e óbitos por faixa etária")
```

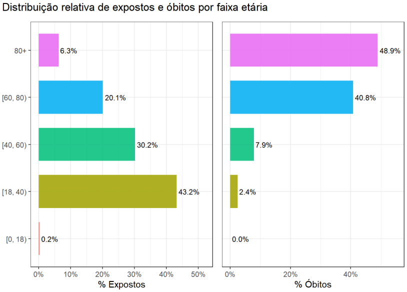

Pirâmide etária da exposição por faixa etária (triênio 2012–2014)

A pirâmide evidencia a assimetria estrutural do fundo: 73.4% dos expostos pertencem às faixas [18, 40) e [40, 60), mas apenas 10.3% dos óbitos. As faixas [60, 80) e 80+ reúnem 26.4% da exposição e 89.7% dos sinistros. Esse desacoplamento é o que justifica o modelo de credibilidade com pesos de volume distintos por faixa: a informação de cada grupo contribui de forma desigual para a estimativa do nível global λ_0.

Distribuição etária da exposição e dos óbitos

▼ Ocultar código

```r
p1 <- ggplot(fundo_long, aes(x = Idade, y = Expostos, colour = Ano)) +
  geom_line(linewidth = 0.9) +
  scale_x_continuous(breaks = seq(0, 110, by = 10)) +
  labs(x = "Idade", y = "Expostos", colour = NULL) +
  theme_bw(base_size = 11) + theme(legend.position = "bottom")
```

```r
p2 <- ggplot(fundo_long, aes(x = Idade, y = Obitos, colour = Ano)) +
  geom_line(linewidth = 0.9) +
  scale_x_continuous(breaks = seq(0, 110, by = 10)) +
  labs(x = "Idade", y = "Óbitos", colour = NULL) +
  theme_bw(base_size = 11) + theme(legend.position = "bottom")

p1 + p2
```

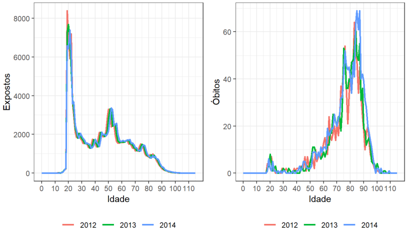

Expostos e óbitos por idade e ano (2012–2014)

▼ Ocultar código

```r
# Variáveis inline para o parágrafo
exp_19_trienio <- sum(fundo_long$Expostos[fundo_long$Idade == 19])
idade_max_obt  <- sum_d2$Idade[which.max(sum_d2$tot_obt)]
obt_max_trienio <- max(sum_d2$tot_obt)
```

A distribuição de expostos exibe dois picos: o principal entre 19 e 22 anos (entrada de jovens no plano, com idade 19 acumulando $\approx 22\,000$ pessoas-ano no triênio) e um secundário entre 40 e 55 anos. Os óbitos concentram-se acima dos 60 anos, com máximo em torno de 84 anos (175 óbitos no triênio). A estabilidade temporal das curvas indica ausência de choques na composição da carteira no período.

Log da taxa de mortalidade e heatmap idade × ano

▼ Ocultar código

```r
ggplot(fundo_long |> filter(!is.na(log_tx)),
       aes(x = Idade, y = log_tx, colour = Ano)) +
  geom_line(linewidth = 0.9) +
  scale_x_continuous(breaks = seq(0, 110, by = 10)) +
  labs(x = "Idade", y = expression(log~hat(m)[x]), colour = NULL) +
  theme_bw(base_size = 12) + theme(legend.position = "bottom")
```

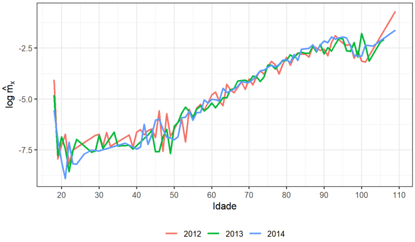

Log da taxa central de mortalidade por idade e ano (2012–2014)

▼ Ocultar código

```r
heat_df <- fundo_long |>
  filter(!is.na(log_tx), Expostos >= 5) |>
  mutate(Ano = as.numeric(Ano))

p_heatmap <- ggplot(
  heat_df |> mutate(tooltip = sprintf("Idade: %d\nAno: %.0f\nlog(m\u0302\u2093) = %.2f",
                                      Idade, Ano, log_tx)),
  aes(x = Ano, y = Idade, fill = log_tx)
) +
  geom_tile_interactive(aes(tooltip = tooltip, data_id = paste(Idade, Ano)),
                        width = 0.95, height = 0.95) +
  scale_fill_scico(palette = "lajolla", direction = 1,
                   name = expression(log~hat(m)[x])) +
  scale_x_continuous(breaks = c(2012, 2013, 2014)) +
  scale_y_continuous(breaks = seq(0, 110, by = 10)) +
  labs(x = "Ano", y = "Idade") +
  theme_bw(base_size = 12)
```

```
girafe(
  ggobj = p_heatmap,
  options = list(
    opts_hover(css = "stroke: white; stroke-width: 0.8px;"),
    opts_tooltip(css = "font-size:12px; padding:5px 8px;"),
    opts_toolbar(saveaspng = FALSE)
  )
)
```

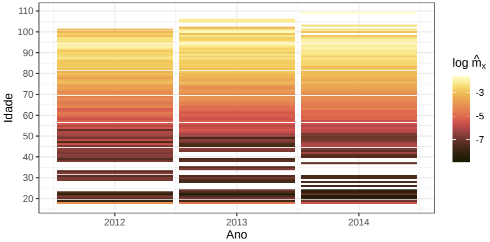

Heatmap de log(taxa central de mortalidade) por idade e ano — superfície de Lexis

O heatmap (superfície de Lexis discreta) apresenta o padrão típico de mortalidade humana: tons mais claros (taxas mais altas) nas idades acima de 70 anos e tons mais escuros (taxas baixas) nas idades jovens. A estrutura é consistente entre os três anos — não há coluna atípica que indique anomalia de registro em nenhum ano específico. Com apenas $T = 3$ períodos, o heatmap serve para diagnóstico de consistência; a inferência de tendência temporal de melhoria de mortalidade requer horizontes mais longos (Rau et al., 2018).

A curva do log da taxa central exibe três segmentos: mínimo entre 5 e 15 anos ($\log \hat{m}_x \approx -10$), elevação suave entre 15 e 25 anos por causas externas, e crescimento aproximadamente linear acima dos 25 anos, compatível com a lei de Gompertz — $m_x \propto e^{\beta x}$, com $\beta \approx 0{,}09$ por ano. Nas idades acima de 90 anos as curvas anuais divergem, pois $E_x \leq 5$ em muitas células: um único óbito adicional desloca $\log \hat{m}_x$ em $\log 2 \approx 0{,}7$ unidades, argumento direto para agregar essas idades num único grupo de risco.

Evolução dos óbitos anuais por faixa etária

▼ Ocultar código

```
if (!requireNamespace("gtExtras", quietly = TRUE))
  install.packages("gtExtras", repos = "https://cloud.r-project.org", quiet = TRUE)
library(gtExtras)

intervalos_q1 <- c(0, 18, 40, 60, 80, 116)
labels_fx_q1  <- c("[0, 18)", "[18, 40)", "[40, 60)", "[60, 80)", "80+")

box_df <- fundo_long |>
  mutate(faixa = cut(Idade, breaks = intervalos_q1, right = FALSE,
                     labels = labels_fx_q1)) |>
  filter(!is.na(faixa)) |>
  group_by(faixa, Ano) |>
  summarise(Obitos = sum(Obitos), .groups = "drop") |>
  mutate(faixa = factor(faixa, levels = labels_fx_q1))

spark_df <- box_df |>
  group_by(faixa) |>
  summarise(
    `2012`     = Obitos[Ano == "2012"],
    `2013`     = Obitos[Ano == "2013"],
    `2014`     = Obitos[Ano == "2014"],
    CV         = if_else(mean(Obitos) > 0,
                         round(sd(Obitos) / mean(Obitos) * 100, 1),
                         NA_real_),
    tendencia = list(Obitos),
    .groups    = "drop"
  )

spark_df |>
  gt() |>
  tab_header(
    title    = "Óbitos anuais por faixa etária (2012–2014)",
    subtitle = "A coluna Trajetória mostra a evolução 2012 → 2013 → 2014"
  ) |>
  cols_label(
    faixa     = "Faixa",
    `2012`    = "2012",
    `2013`    = "2013",
    `2014`    = "2014",
    CV        = "CV (%)",
    tendencia = "Trajetória"
  ) |>
  gt_plt_sparkline(
    tendencia,
    type       = "default",
    same_limit = FALSE,
```

```
    palette    = c("steelblue4", "steelblue4", "steelblue4", "steelblue4", "steelblue4")
  ) |>
  tab_style(
    style     = cell_fill(color = "white"),
    locations = cells_body(columns = tendencia)
  ) |>
  sub_missing(columns = CV, missing_text = "—") |>
  fmt_number(columns = c(`2012`, `2013`, `2014`), decimals = 0) |>
  tab_style(
    style     = cell_fill(color = "#FFF9C4"),
    locations = cells_body(rows = !is.na(CV) & CV > 15)
  ) |>
  tab_style(
    style     = list(cell_fill("#EBF5FB"), cell_text(weight = "bold")),
    locations = cells_body(rows = faixa == "80+")
  ) |>
  tab_style(
    style     = cell_text(color = "grey50", style = "italic"),
    locations = cells_body(rows = faixa == "[0, 18)")
  ) |>
  cols_align(align = "center", columns = c(`2012`, `2013`, `2014`, CV)) |>
  tab_options(
    table.font.size        = 13,
    table.width            = pct(80),
    column_labels.font.weight = "bold",
    heading.subtitle.font.size = 11
  )
```

Óbitos anuais por faixa etária (2012–2014)

A coluna Trajetória mostra a evolução 2012 → 2013 → 2014

Faixa	**2012**	**2013**	**2014**	**CV (%)**	**Trajetória**
[0, 18)	*0*	*0*	*0*	—	
[18, 40)	34	33	22	22.4	
[40, 60)	97	92	99	3.8	
[60, 80)	476	484	531	6.0	
80+	**524**	**583**	**683**	**13.5**	

A tabela com sparklines comprime em uma linha por grupo toda a informação relevante: os três valores anuais, o CV e a trajetória visual. A faixa 80+ (destacada em azul) exibe crescimento monotônico de 524 para 583 para 683 óbitos, sinal do envelhecimento progressivo da carteira. A faixa $[18, 40)$ tem CV elevado (22.4%, destacado em amarelo) por oscilar entre 22 e 34 óbitos por ano. A faixa $[0, 18)$ registra zero óbitos nos três anos; sua taxa credibilizada virá inteiramente do nível coletivo $\hat{\lambda}_0$.

Curva de sobrevivência acumulada

▼ Ocultar código

```
# lx construída a partir das mx do triênio acumulado
lx_df <- sum_d2 |>
  arrange(Idade) |>
  mutate(
    mx   = if_else(tot_exp > 0, tot_obt / tot_exp, 0),
    px   = exp(-mx),           # probabilidade de sobreviver 1 ano (força constante)
    lx   = cumprod(c(1, px[-n()])) * 100000   # radix = 100.000
  )

ggplot(lx_df |> filter(Idade <= 110), aes(x = Idade, y = lx)) +
  geom_line(linewidth = 1.0, colour = "steelblue4") +
  geom_area(alpha = 0.15, fill = "steelblue") +
  geom_vline(xintercept = c(18, 40, 60, 80),
             linetype = "dotted", colour = "grey40", linewidth = 0.7) +
  scale_x_continuous(breaks = seq(0, 110, by = 10)) +
  scale_y_continuous(labels = scales::comma_format(big.mark = ".")) +
  labs(x = "Idade", y = expression(italic(l)[x]~"(radix = 100.000)")) +
  theme_bw(base_size = 12)
```

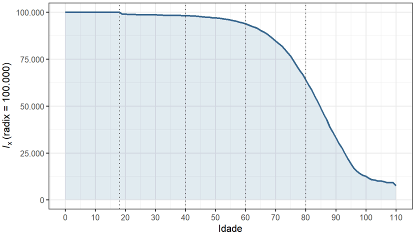

Função de sobrevivência acumulada l_x a partir das taxas centrais observadas (triênio 2012–2014)

A curva l_x parte de 100.000 nascidos vivos e decresce de acordo com as taxas centrais observadas no triênio, sob a hipótese de força de mortalidade constante dentro de cada ano de idade ($p_x = e^{-\hat{m}_x}$). A queda mais acentuada ocorre acima dos 60 anos, com a curva atingindo ≈ 64.100 aos 80 anos — consistente com o índice de dependência de 0.359 calculado anteriormente. As linhas pontilhadas marcam as fronteiras das faixas etárias definidas na questão (ii).

Questão (ii): Perfil Etário e Faixas de Risco

Critérios de formação dos grupos

A definição dos m grupos para o modelo de Bühlmann-Straub obedece a três critérios simultâneos, seguindo Pitacco et al. (2009) e Bühlmann; Gisler (2005):

Homogeneidade interna. As taxas individuais dentro de cada faixa devem variar suavemente para que a taxa agregada seja representativa. A linearidade em log nas faixas adultas indica que intervalos de 20 anos mantêm homogeneidade razoável.

Exposição suficiente. O modelo pondera cada observação pelo volume $v_{it} = E_{it}$ (pessoas-ano). Com $T = 2$ anos de ajuste e $m = 4$ grupos (excluindo $[0, 18)$ por ausência de sinistros), os parâmetros estruturais $\hat{\lambda}_0$ e $\hat{\tau}^2$ são estimados com $m - 1 = 3$ graus de liberdade para a componente entre grupos. Grupos com $v_{it} \approx 0$ recebem peso negligenciável automaticamente.

Relevância atuarial. Os grupos devem capturar os regimes de risco que impactam o passivo do plano: jovens ativos, núcleo produtivo, aposentados recentes e idosos avançados.

Faixas etárias e estatísticas descritivas

▼ Ocultar código

```r
sum_faixas <- sum_d2 |>
  group_by(faixa) |>
  summarise(
    tot_obt = sum(tot_obt),
    tot_exp = sum(tot_exp),
    .groups = "drop"
  ) |>
  mutate(
    tx_media = tot_obt / tot_exp,
    pct_exp  = tot_exp / sum(tot_exp),
    pct_obt  = tot_obt / sum(tot_obt)
  )

# Coeficiente de variação dos óbitos anuais por faixa
cv_data <- tibble(
  faixa  = labels_fx,
  obt_12 = c(0, 34, 97,  476, 524),
  obt_13 = c(0, 33, 92,  484, 583),
  obt_14 = c(0, 22, 99,  531, 683)
) |>
  rowwise() |>
  mutate(
    media = mean(c(obt_12, obt_13, obt_14)),
    cv    = if_else(media > 0,
                    sd(c(obt_12, obt_13, obt_14)) / media, NA_real_)
  )

sum_faixas |>
  left_join(cv_data |> select(faixa, cv), by = "faixa") |>
  gt() |>
  tab_header(title = "Resumo por faixa etária (triênio 2012--2014)") |>
  cols_label(
    faixa    = "Faixa",
    tot_obt  = "Óbitos",
    tot_exp  = "Expostos",
    tx_media = md("$\\hat{m}$ média"),
    pct_exp  = "% Expostos",
    pct_obt  = "% Óbitos",
    cv       = "CV óbitos anuais"
  ) |>
  fmt_number(columns = c(tot_obt, tot_exp), decimals = 0) |>
  fmt_number(columns = tx_media, decimals = 6) |>
  fmt_percent(columns = c(pct_exp, pct_obt), decimals = 1) |>
  fmt_number(columns = cv, decimals = 3) |>
  tab_options(table.font.size = 13)
```

Resumo por faixa etária (triênio 2012--2014)

Faixa	Óbitos	Expostos	$\hat{m}$ média	% Expostos	% Óbitos	CV óbitos anuais
[0, 18)	0	1,029	0.000000	0.2%	0.0%	NA
[18, 40)	89	180,635	0.000493	43.2%	2.4%	0.224
[40, 60)	288	126,107	0.002284	30.2%	7.9%	0.038
[60, 80)	1,491	84,038	0.017742	20.1%	40.8%	0.060
80+	1,790	26,155	0.068438	6.3%	48.9%	0.135

▼ Ocultar código

```
# Variáveis inline dos CVs
cv_4060 <- round(cv_data$cv[cv_data$faixa == "[40, 60)"] * 100, 1)
cv_1840 <- round(cv_data$cv[cv_data$faixa == "[18, 40)"] * 100, 1)
cv_80p  <- round(cv_data$cv[cv_data$faixa == "80+"]      * 100, 1)
```

O coeficiente de variação (CV) dos óbitos anuais quantifica a estabilidade temporal de cada grupo. A faixa [40, 60) tem CV $= 3.8\%$, a mais estável, enquanto [18, 40) atinge 22.4%, reflexo de contagens baixas e raras em que um ou dois óbitos a mais ou a menos representam variação percentual expressiva. A faixa $80+$ tem CV $= 13.5\%$ por exposição reduzida em idades muito avançadas. No modelo de Bühlmann-Straub, esses grupos de alta variabilidade recebem menor peso v_{it} e, consequentemente, menor credibilidade ω_i em favor do nível coletivo λ_0.

Visualização das faixas e curva de mortalidade

▼ Ocultar código

```
sum_d2_tx <- sum_d2 |>
  mutate(tx_tot = if_else(tot_exp > 0, tot_obt / tot_exp, NA_real_)) |>
  filter(!is.na(tx_tot), tx_tot > 0)

p_faixas <- ggplot(
  sum_d2_tx |>
    mutate(tooltip = sprintf("Faixa: %s\nIdade: %d\nm\u0302\u2093 = %.5f", faixa, Idade, tx_tot)
  aes(x = Idade, y = tx_tot, colour = faixa)
) +
  geom_point_interactive(aes(tooltip = tooltip, data_id = faixa),
                         size = 1.8) +
  geom_vline(xintercept = c(18, 40, 60, 80),
             linetype = "dotted", colour = "grey40", linewidth = 0.7) +
  scale_colour_scico_d(palette = "batlow", name = "Faixa") +
  scale_y_log10(
    breaks = 10^(-5:-1),
    labels = scales::trans_format("log10", scales::math_format(10^.x))
  ) +
  scale_x_continuous(breaks = seq(0, 110, by = 10)) +
  labs(x = "Idade", y = expression(hat(m)[x]~"(escala log)")) +
  theme_bw(base_size = 12) + theme(legend.position = "bottom")

girafe(
  ggobj = p_faixas,
  options = list(
    opts_hover(css = "r:5px;"),
    opts_hover_inv(css = "opacity:0.2;"),
    opts_tooltip(css = "font-size:12px; padding:5px 8px;"),
    opts_toolbar(saveaspng = FALSE)
  )
)
```

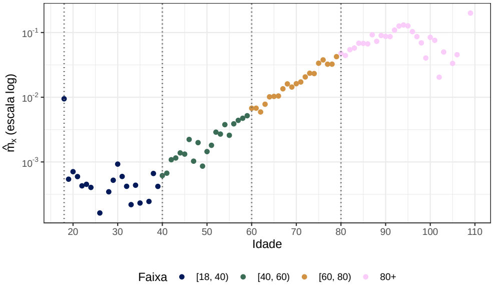

Taxa central de mortalidade total com fronteiras das faixas de risco (eixo log)

As fronteiras $x \in \{18, 40, 60, 80\}$ coincidem com inflexões ou mudanças de regime na curva: em $x = 18$ isola-se a mortalidade infantojuvenil; em $x = 40$, a transição para a meia-idade; em $x = 60$, o início da mortalidade degenerativa acelerada; em $x = 80$, o isolamento das idades com exposição muito reduzida e taxa elevada.

Questão (iii): Seleção de Tábuas de Referência

Contexto regulatório e das tábuas

A escolha da tábua de referência é relevante para o modelo de Bühlmann-Straub porque ela define o nível coletivo $\hat{\lambda}_0$ ao qual as estimativas individuais de cada grupo são encolhidas. Uma tábua sistematicamente inadequada introduz viés em todos os prêmios de credibilidade (Bühlmann; Gisler, 2005).

No Brasil, a referência regulatória para EFPCs é estabelecida pela Resolução CNPC nº 30/2018 e pela

Portaria PREVIC nº 835/2020 (PREVIC, 2020), que determinam a realização de pelo menos dois testes estatísticos de aderência. Avaliamos:

- **AT-2000 masculina** (Society of Actuaries, 2000): tábua americana de rentistas, adotada historicamente no Brasil por ausência de alternativa nacional. A principal limitação é o viés de tradução demográfica: a mortalidade americana de rentistas de 2000 difere substancialmente da mortalidade brasileira atual.
- **BR-EMSsb-m v.2021** (FenaPrevi, 2021): tábua construída com dados de apólices do mercado segurador brasileiro, publicada pela FenaPrevi em 2021. Representa a experiência nacional mais recente e é a referência regulatória atual.

▼ Ocultar código

```r
at2000 <- read.csv("at2000.iba.csv",    header = TRUE, dec = ",")
brems  <- read.csv("brems2021.iba.csv", header = TRUE, dec = ",")

# Os dados fornecem a taxa central mx = Dx/Ex. As tábuas de referência estão
# em qx. Convertemos: qx_obs = 1 - exp(-mx), para que a comparação e a razão
# A/E sejam conceitualmente coerentes (observado e esperado na mesma escala).
frame_comp <- sum_d2 |>
  select(Idade, tot_obt, tot_exp) |>
  mutate(
    mx_obs    = if_else(tot_exp > 0, tot_obt / tot_exp, NA_real_),
    qx_obs    = if_else(!is.na(mx_obs), 1 - exp(-mx_obs), NA_real_),
    at2000_m = at2000$at2000.m,
    brems_m  = brems$brems2021sb.m[1:116],
    obt_at    = tot_exp * at2000_m,
    obt_br    = tot_exp * brems_m
  )
```

Comparação visual das tábuas

▼ Ocultar código

```r
ggplot(frame_comp |> filter(!is.na(qx_obs), qx_obs > 0), aes(x = Idade)) +
  geom_point(aes(y = qx_obs, colour = "Observado"), size = 1.2, alpha = 0.55) +
  geom_line(aes(y = at2000_m, colour = "AT-2000-m"), linewidth = 0.95) +
  geom_line(aes(y = brems_m,  colour = "BR-EMSsb-m v.2021"), linewidth = 0.95) +

  scale_y_log10(
    breaks = 10^(-5:-1),
    labels = scales::trans_format("log10", scales::math_format(10^.x))
  ) +
  scale_x_continuous(breaks = seq(0, 110, by = 10)) +
  labs(x = "Idade", y = expression(q[x]~"(escala log)")) +
  theme_bw(base_size = 12) + theme(legend.position = "bottom")
```

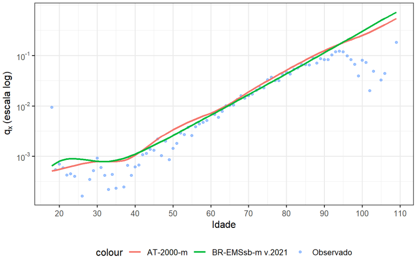

Comparação das tábuas com a experiência observada (escala log; observado convertido para $\hat{q}_x = 1 - e^{-\hat{m}_x}$)

Razão A/E por faixa etária

Os dados do fundo fornecem diretamente a **taxa central de mortalidade** $\hat{m}_x = D_x/E_x$, enquanto as tábuas AT-2000 e BR-EMSsb-m estão calibradas em **probabilidade de morte** q_x. Para que a comparação e a razão A/E sejam conceitualmente coerentes (observado e esperado na mesma escala), convertemos a taxa central observada por meio da relação de força constante:

$$\hat{q}_x = 1 - e^{-\hat{m}_x}.$$

A razão A/E por faixa agrega os esperados ponderados pela exposição:

$$\mathrm{A/E}_j = \frac{\sum_{x \in j} D_x}{\sum_{x \in j} E_x \cdot q_x^{\text{tábua}}}$$

▼ Ocultar código

```r
frame_ae <- frame_comp |>
  mutate(faixa = cut(Idade, breaks = intervalos, right = FALSE, labels = labels_fx)) |>
  group_by(faixa) |>
  summarise(
    obt_obs = sum(tot_obt),
```

```r
    esp_at  = sum(obt_at, na.rm = TRUE),
    esp_br  = sum(obt_br, na.rm = TRUE),
    .groups = "drop"
  ) |>
  mutate(ae_at = obt_obs / esp_at, ae_br = obt_obs / esp_br)

frame_ae |>
  gt() |>
  tab_header(title = "Razão A/E por faixa etária (triênio 2012--2014)") |>
  cols_label(
    faixa   = "Faixa", obt_obs = "Óbitos obs.",
    esp_at  = "Esp. AT-2000", esp_br = "Esp. BR-EMS",
    ae_at   = "A/E AT-2000",  ae_br  = "A/E BR-EMS"
  ) |>
  fmt_number(columns = c(obt_obs, esp_at, esp_br), decimals = 1) |>
  fmt_number(columns = c(ae_at, ae_br), decimals = 3) |>
  tab_style(
    style     = cell_fill(color = "#D5F5E3"),
    locations = cells_body(columns = ae_br, rows = abs(ae_br - 1) < abs(ae_at - 1))
  ) |>
  tab_options(table.font.size = 13)
```

Razão A/E por faixa etária (triênio 2012--2014)

Faixa	Óbitos obs.	Esp. AT-2000	Esp. BR-EMS	A/E AT-2000	A/E BR-EMS
[0, 18)	0.0	0.5	0.5	0.000	0.000
[18, 40)	89.0	119.9	150.9	0.742	0.590
[40, 60)	288.0	441.5	362.6	0.652	0.794
[60, 80)	1,491.0	1,638.7	1,445.1	0.910	1.032
80+	1,790.0	2,361.7	2,160.1	0.758	0.829

▼ Ocultar código

```r
ae_long <- frame_ae |>
  select(faixa, ae_at, ae_br) |>
  pivot_longer(c(ae_at, ae_br), names_to = "tabua", values_to = "ae") |>
  mutate(
    tabua   = recode(tabua, ae_at = "AT-2000-m", ae_br = "BR-EMSsb-m v.2021"),
    tooltip = sprintf("Faixa: %s\nTábua: %s\nA/E = %.3f", faixa, tabua, ae)
  )

p_ae <- ggplot(ae_long, aes(x = faixa, y = ae, colour = tabua, group = tabua)) +
  geom_line_interactive(linewidth = 0.9) +
  geom_point_interactive(aes(tooltip = tooltip, data_id = paste(faixa, tabua)),
                         size = 3.5) +
  geom_hline(yintercept = 1, linetype = "dashed", colour = "grey40") +
  labs(x = "Faixa etária", y = "A/E") +
  theme_bw(base_size = 12) + theme(legend.position = "bottom")

girafe(
  ggobj = p_ae,
  options = list(
    opts_hover(css = "r:6px;"),
    opts_hover_inv(css = "opacity:0.25;"),
    opts_tooltip(css = "font-size:12px; padding:5px 8px;"),
    opts_toolbar(saveaspng = FALSE)
  )
)
```

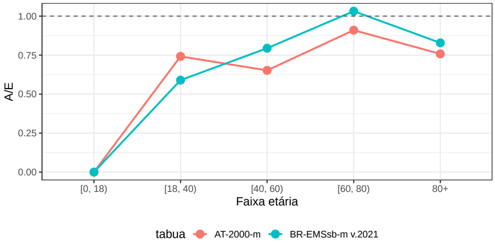

Razão A/E por faixa etária

A AT-2000 superestima a mortalidade em todas as faixas (A/E <1). A BR-EMSsb-m v.2021 é mais aderente: apresenta A/E próximo de 1 nas faixas intermediárias, subestima ligeiramente em [60, 80) (A/E $=1.032$) e superestima em $80+$ (A/E $=0.829$), provavelmente por instabilidade das taxas observadas nessa faixa.

Testes estatísticos de aderência

A comparação visual e a razão A/E fornecem diagnóstico qualitativo; para a exigência regulatória da Portaria PREVIC nº 835/2020 (PREVIC, 2020), são necessários pelo menos dois testes formais. Utilizamos o pacote `mortalityAdherence` de Melo; Graziadei; Targino (2026), que implementa 11 testes em quatro famílias:

- **Não-paramétricos** (KS, Qui-quadrado): testam se a distribuição empírica dos óbitos por idade é compatível com a esperada pela tábua, sem hipótese paramétrica para o processo de contagem.
- **Poisson Tipo I** (Wald e LRT): testam $H_0 : \text{A/E global} = 1$, com $D_x \sim \text{Poisson}(E_x \cdot q_x)$ sob a tábua.
- **Poisson Tipo II** (Wald e LRT): testam ausência de viés etário, ou seja, se a razão observado/esperado é constante ao longo das idades.
- **Binomial Negativo** (Tipo I e II): versões robustas à superdispersão. Rejeição nos testes NB confirma que o desajuste é real e não artefato da hipótese Poisson.
- **Intervalo bayesiano (BayesCI)**: verifica se a A/E observada está dentro do intervalo credível a 95% sob priori de Jeffreys para $\theta = q_{\text{obs}}/q_{\text{tábua}}$.

▼ Ocultar código

```
fund_adh <- sum_d2 |> select(age = Idade, exposed = tot_exp, deaths = tot_obt)
tab_at   <- data.frame(age = at2000$idade,       qx = at2000$at2000.m)
tab_br   <- data.frame(age = brems$idade[1:116], qx = brems$brems2021sb.m[1:116])

res_at <- testAdherence(fund_adh, table = tab_at, alpha = 0.05)
res_br <- testAdherence(fund_adh, table = tab_br, alpha = 0.05)
```

▼ Ocultar código

```
res_at$summary |>
  select(test, description, family, statistic, p_value, reject_h0) |>
  gt() |>
  tab_header(
    title    = "Testes de aderência --- AT-2000 masculina",
    subtitle = md(sprintf("A/E = %.4f &nbsp;|&nbsp; Obs: %d &nbsp;|&nbsp; Esp: %.1f",
                          res_at$ae_ratio, res_at$observed_deaths, res_at$expected_deaths))
  ) |>
  cols_label(test="Teste", description="Descrição", family="Família",
             statistic="Estatística", p_value=md("$p$-valor"), reject_h0=md("Rejeita $H_0$?")) |
  fmt_number(columns = c(statistic, p_value), decimals = 4) |>
  tab_style(style=cell_fill("#FDECEA"), locations=cells_body(rows=reject_h0=="Yes")) |>
  tab_style(style=cell_fill("#E8F5E9"), locations=cells_body(rows=reject_h0=="No"))  |>
  tab_style(style=cell_text(weight="bold"), locations=cells_body(columns=reject_h0)) |>
  tab_options(table.font.size = 13)
```

Testes de aderência --- AT-2000 masculina

A/E = 0.8018 | Obs: 3658 | Esp: 4562.4

Teste	Descrição	Família	Estatística	$p$-valor	Rejeita $H_0$?
KS	Kolmogorov-Smirnov	Non-parametric	0.0508	NA	**Yes**
ChiSquare	Chi-Square Goodness-of-Fit	Non-parametric	469.3741	0.0000	**Yes**
WaldI_P	Wald Type I (Poisson)	Poisson	−13.3619	0.0000	**Yes**
WaldII_P	Wald Type II — age slope (Poisson)	Poisson	NA	0.0000	**Yes**
LRTI_P	LRT Type I (Poisson)	Poisson	192.4492	0.0000	**Yes**
LRTII_P	LRT Type II — age slope (Poisson)	Poisson	199.4474	0.0000	**Yes**
BayesCI	Bayesian Credibility Interval	Bayesian	NA	NA	**Yes**
WaldI_NB	Wald Type I (Negative Binomial)	Negative Binomial	−8.1180	0.0000	**Yes**
WaldII_NB	Wald Type II — age slope (Neg. Binomial)	Negative Binomial	NA	0.0000	**Yes**
LRTI_NB	LRT Type I (Negative Binomial)	Negative Binomial	44.2823	0.0000	**Yes**
LRTII_NB	LRT Type II — age slope (Neg. Binomial)	Negative Binomial	52.6410	0.0000	**Yes**

▼ Ocultar código

```
res_br$summary |>
  select(test, description, family, statistic, p_value, reject_h0) |>
  gt() |>
  tab_header(
    title    = "Testes de aderência --- BR-EMSsb-m v.2021",
    subtitle = md(sprintf("A/E = %.4f &nbsp;|&nbsp; Obs: %d &nbsp;|&nbsp; Esp: %.1f",
                          res_br$ae_ratio, res_br$observed_deaths, res_br$expected_deaths))
  ) |>
  cols_label(test="Teste", description="Descrição", family="Família",
             statistic="Estatística", p_value=md("$p$-valor"), reject_h0=md("Rejeita $H_0$?")) |
  fmt_number(columns = c(statistic, p_value), decimals = 4) |>
  tab_style(style=cell_fill("#FDECEA"), locations=cells_body(rows=reject_h0=="Yes")) |>
  tab_style(style=cell_fill("#E8F5E9"), locations=cells_body(rows=reject_h0=="No"))  |>
  tab_style(style=cell_text(weight="bold"), locations=cells_body(columns=reject_h0)) |>
  tab_options(table.font.size = 13)
```

Testes de aderência --- BR-EMSsb-m v.2021

A/E = 0.8880 | Obs: 3658 | Esp: 4119.1

Teste	Descrição	Família	Estatística	$p$-valor	Rejeita $H_0$?
KS	Kolmogorov-Smirnov	Non-parametric	0.0726	NA	**Yes**
ChiSquare	Chi-Square Goodness-of-Fit	Non-parametric	408.5956	0.0000	**Yes**
WaldI_P	Wald Type I (Poisson)	Poisson	−7.1810	0.0000	**Yes**
WaldII_P	Wald Type II — age slope (Poisson)	Poisson	NA	0.0000	**Yes**
LRTI_P	LRT Type I (Poisson)	Poisson	53.6692	0.0000	**Yes**
LRTII_P	LRT Type II — age slope (Poisson)	Poisson	60.4761	0.0000	**Yes**

BayesCI	Bayesian Credibility Interval	Bayesian	NA	NA	**Yes**
WaldI_NB	Wald Type I (Negative Binomial)	Negative Binomial	−5.2910	0.0000	**Yes**
WaldII_NB	Wald Type II — age slope (Neg. Binomial)	Negative Binomial	NA	0.0000	**Yes**
LRTI_NB	LRT Type I (Negative Binomial)	Negative Binomial	23.2139	0.0000	**Yes**
LRTII_NB	LRT Type II — age slope (Neg. Binomial)	Negative Binomial	28.1877	0.0000	**Yes**

Os campos `NA` na coluna de estatística correspondem a testes cujo resultado é expresso por um $p$-valor direto sem estatística de teste escalar (Wald Tipo II, que usa estatística matricial) ou que não produzem $p$-valor analítico (KS assintótico, BayesCI baseado em intervalo). Isso não indica falha computacional; é uma característica do design dos testes Melo; Graziadei; Targino (2026).

Ambas as tábuas rejeitam $H_0$ nos 11 testes. Com 3658 óbitos e A/E $= 0.89$ para a BR-EMS, o desvio representa ≈ 7 erros-padrão Poisson $(\mathrm{DP} \approx 1/\sqrt{4119} \approx 0.016)$, tornando a rejeição praticamente certa para qualquer α usual. A rejeição universal é esperada quando a tábua não foi calibrada especificamente para a população analisada (Melo; Graziadei; Targino, 2026). A BR-EMS produz estatísticas de teste substancialmente menores (Qui-quadrado: $469 \to 409$; LRT Poisson: $192 \to 54$), confirmando menor grau de desajuste. Os testes NB também rejeitam, descartando superdispersão como explicação alternativa. A BR-EMSsb-m v.2021 é, portanto, a tábua de referência adotada para o modelo de Bühlmann-Straub.

Questão (iv): Definição dos Perfis de Risco

Grupos adotados

▼ Ocultar código

```r
labels_fx_m4  <- c("[18, 40)", "[40, 60)", "[60, 80)", "80+")

tibble(
  Grupo = 1:4,
  Faixa = labels_fx_m4,
  Descrição = c(
    "Jovens trabalhadores; mortalidade baixa; CV = 22,4%",
    "Trabalhadores ativos; mortalidade crescente; CV = 3,8%",
    "Aposentados; 40,8% dos óbitos; CV = 6,0%",
    "Idosos avançados; mortalidade alta e instável; CV = 13,5%"
  )
) |>
  left_join(sum_faixas |> select(faixa, tot_exp, tot_obt, tx_media),
            by = c("Faixa" = "faixa")) |>
  gt() |>
  tab_header(
    title    = "Perfis de risco para o modelo de Bühlmann-Straub ($m = 4$)",
    subtitle = "A faixa [0, 18) é excluída do modelo por ausência de sinistros em 2012--2013"
  ) |>
  cols_label(
    Grupo="Grupo", Faixa="Faixa", Descrição="Caracterização",
    tot_exp="Expostos totais", tot_obt="Óbitos totais",
    tx_media=md("$\\hat{m}$ média")
  ) |>
  fmt_number(columns = c(tot_exp, tot_obt), decimals = 0) |>
  fmt_number(columns = tx_media, decimals = 6) |>
  tab_options(table.font.size = 13)
```

Perfis de risco para o modelo de Bühlmann-Straub ($m = 4$)

A faixa [0, 18) é excluída do modelo por ausência de sinistros em 2012--2013

Grupo	Faixa	Caracterização	Expostos totais	Óbitos totais	$\hat{m}$ média
1	[18, 40)	Jovens trabalhadores; mortalidade baixa; CV = 22,4%	180,635	89	0.000493
2	[40, 60)	Trabalhadores ativos; mortalidade crescente; CV = 3,8%	126,107	288	0.002284
3	[60, 80)	Aposentados; 40,8% dos óbitos; CV = 6,0%	84,038	1,491	0.017742
4	80+	Idosos avançados; mortalidade alta e instável; CV = 13,5%	26,155	1,790	0.068438

Questão (v): Modelo de Bühlmann-Straub — Frequência de Sinistros

Formulação do modelo

Seguindo Bühlmann; Gisler (2005) e Klugman; Panjer; Willmot (2012), define-se para cada grupo de risco $i = 1, \ldots, m$ e período $t = 1, 2$:

$$F_{it} = \frac{N_{it}}{v_{it}}, \qquad E[N_{it} \mid \theta_i] = \mathrm{Var}[N_{it} \mid \theta_i] = v_{it}\,\lambda(\theta_i), \quad \text{com } \lambda(\theta_i) = \lambda_0\,\theta_i,$$

onde N_{it} é o número de óbitos do grupo i no ano t e $v_{it} = E_{it}$ é a exposição (pessoas-ano). A hipótese $E[N_{it} \mid \theta_i] = \mathrm{Var}[N_{it} \mid \theta_i]$ decorre diretamente da distribuição Poisson condicional, consequência natural da dinâmica de contagem do diagrama de Lexis (Rau et al., 2018).

Este modelo é um caso particular do modelo de Bühlmann-Straub com $X_{it} = F_{it}$ e $\sigma^2(\theta_i) = \lambda(\theta_i)$. Os parâmetros estruturais reduzem-se a apenas dois: o nível global λ_0 e a variância entre grupos τ^2, com $\sigma^2 = \lambda_0$ (Bühlmann; Gisler, 2005, cap. 4).

A faixa $[0, 18)$ é excluída da análise de credibilidade pois não apresenta sinistros em 2012–2013, tornando a frequência observada identicamente nula e inviabilizando a estimação de uma taxa própria. O modelo opera com $m = 4$ grupos: $[18, 40)$, $[40, 60)$, $[60, 80)$ e $80+$.

O modelo é **ajustado com os dados de 2012 e 2013** ($T = 2$) e a previsão para 2014 é confrontada com os óbitos efetivamente observados nesse ano, servindo como validação fora da amostra.

Estimação iterativa de λ_0 e τ^2

Como os estimadores de λ_0 e τ^2 são mutuamente dependentes, a estimação é feita iterativamente. Definindo as quantidades auxiliares (Bühlmann; Gisler, 2005):

$$c_1 = \frac{m-1}{m}\left\{\sum_i \frac{v_i}{v}\left(1 - \frac{v_i}{v}\right)\right\}^{-1}, \qquad c_2 = \frac{m}{m-1}\sum_i \frac{v_i}{v}\left(\bar{F}_i^v - \bar{\bar{F}}^v\right)^2,$$

onde $v_i = \sum_{t=1}^{2} v_{it}$ e $v = \sum_i v_i$ (total de pessoas-ano em 2012–2013 para os $m = 4$ grupos); a frequência volume ponderada do grupo i é $\bar{F}_i^v = \sum_t (v_{it}/v_i)\, F_{it}$; e $\bar{\bar{F}}^v = \sum_i (v_i/v)\, \bar{F}_i^v$ é a média global.

O algoritmo inicia com $\hat{\lambda}_0^{(0)} = \bar{\bar{F}}^v$ e itera:

$$\hat{\kappa}^{(k)} = \frac{\hat{\lambda}_0^{(k)}}{\hat{\tau}^{2(k)}}, \qquad \hat{\omega}_i^{(k)} = \frac{v_i}{v_i + \hat{\kappa}^{(k)}},$$

$$\hat{\lambda}_0^{(k+1)} = \sum_i \frac{\hat{\omega}_i^{(k)}}{\hat{\omega}^{(k)}}\, \bar{F}_i^v, \qquad \hat{\tau}^{2(k+1)} = \max\left\{0,\ c_1\left(c_2 - \frac{m\hat{\lambda}_0^{(k)}}{v}\right)\right\}.$$

▼ Ocultar código

```r
intervalos_num <- c(0, 18, 40, 60, 80, 116)

# Dados por grupo e ano — TODOS os 3 anos (necessário para previsão e validação)
bs_data <- fundo_long |>
  mutate(faixa = cut(Idade, breaks = intervalos_num, right = FALSE,
                     labels = labels_fx)) |>
  filter(!is.na(faixa)) |>
  group_by(faixa, Ano) |>
  summarise(vit = sum(Expostos), Nit = sum(Obitos), .groups = "drop") |>
  mutate(Fit = if_else(vit > 0, Nit / vit, 0))

# ── AJUSTE: apenas 2012-2013 e m=4 grupos (exclui [0,18) — zero sinistros) ──
bs_ajuste <- bs_data |>
  filter(Ano %in% c("2012", "2013"), faixa != "[0, 18)")

vi_df <- bs_ajuste |>
  group_by(faixa) |>
  summarise(
    vi     = sum(vit),
    Ni     = sum(Nit),
    Fbar_v = sum(vit * Fit) / sum(vit),
    .groups = "drop"
  )
v_total <- sum(vi_df$vi)
m       <- nrow(vi_df)

# Fbarbar (média global volume ponderada, 2012-2013)
Fbarbar <- sum(vi_df$vi * vi_df$Fbar_v) / v_total

# c1, c2
c1_denom <- sum((vi_df$vi / v_total) * (1 - vi_df$vi / v_total))
c1 <- ((m - 1) / m) / c1_denom
c2 <- (m / (m - 1)) * sum((vi_df$vi / v_total) * (vi_df$Fbar_v - Fbarbar)^2)

cat(sprintf("Ajuste: 2012-2013 | v = %d | m = %d | F̿ = %.6f\n",
            v_total, m, Fbarbar))
```

```
Ajuste: 2012-2013 | v = 276007 | m = 4 | F̿ = 0.008416
```

▼ Ocultar código

```r
cat(sprintf("c1 = %.6f | c2 = %.8f\n", c1, c2))
```

```
c1 = 1.111937 | c2 = 0.00033687
```

▼ Ocultar código

```r
# Algoritmo iterativo
lam0 <- Fbarbar
tau2 <- max(0, c1 * (c2 - m * lam0 / v_total))
iter_log <- tibble(k = 0, lam0 = lam0, tau2 = tau2)

for (k in seq_len(50)) {
  if (tau2 <= 0) break
  kappa    <- lam0 / tau2
  omega_i  <- vi_df$vi / (vi_df$vi + kappa)
  lam0_new <- sum(omega_i / sum(omega_i) * vi_df$Fbar_v)
  tau2_new <- max(0, c1 * (c2 - m * lam0_new / v_total))
```

```r
  iter_log <- bind_rows(iter_log, tibble(k = k, lam0 = lam0_new, tau2 = tau2_new))
  if (abs(lam0_new - lam0) < 1e-10 && abs(tau2_new - tau2) < 1e-12) {
    lam0 <- lam0_new; tau2 <- tau2_new; break
  }
  lam0 <- lam0_new; tau2 <- tau2_new
}

cat(sprintf("\nConvergência em %d iterações\n", nrow(iter_log) - 1))
```

```
Convergência em 4 iterações
```

▼ Ocultar código

```r
cat(sprintf("lambda0_hat = %.8f\n", lam0))
```

```
lambda0_hat = 0.02131241
```

▼ Ocultar código

```r
cat(sprintf("tau2_hat    = %.8f\n", tau2))
```

```
tau2_hat    = 0.00037424
```

▼ Ocultar código

```r
cat(sprintf("kappa_hat   = %.4f\n",  lam0 / tau2))
```

```
kappa_hat   = 56.9488
```

▼ Ocultar código

```r
iter_log |>
  head(8) |>
  gt() |>
  tab_header(title = "Trajetória do algoritmo iterativo (ajuste 2012--2013)") |>
  cols_label(k    = "Iteração",
             lam0 = md("$\\hat{\\lambda}_0^{(k)}$"),
             tau2 = md("$\\hat{\\tau}^{2(k)}$")) |>
  fmt_number(columns = c(lam0, tau2), decimals = 8) |>
  tab_options(table.font.size = 13)
```

Trajetória do algoritmo iterativo (ajuste 2012--2013)

Iteração	$\hat{\lambda}_0^{(k)}$	$\hat{\tau}^{2(k)}$
0	0.00841645	0.00037445
1	0.02133048	0.00037424
2	0.02131239	0.00037424
3	0.02131241	0.00037424
4	0.02131241	0.00037424

Parâmetros estruturais e fatores de credibilidade

▼ Ocultar código

```r
kappa_hat <- lam0 / tau2

resultados <- vi_df |>
  mutate(
    omega_i  = vi / (vi + kappa_hat),
    lam_cred = omega_i * Fbar_v + (1 - omega_i) * lam0
  )

tibble(
  Parâmetro = c(
    "$\\hat{\\lambda}_0$ (nível global)",
    "$\\hat{\\tau}^2$ (variância entre grupos)",
    "$\\hat{\\sigma}^2 = \\hat{\\lambda}_0$ (variância de processo)",
    "$\\hat{\\kappa} = \\hat{\\lambda}_0/\\hat{\\tau}^2$"
  ),
  Valor = c(lam0, tau2, lam0, kappa_hat)
) |>
  gt() |>
  tab_header(title = "Parâmetros estruturais estimados (ajuste 2012--2013)") |>
  cols_label(Parâmetro = md("Parâmetro")) |>
  fmt_markdown(columns = Parâmetro) |>
  fmt_number(columns = Valor, decimals = 6) |>
  tab_options(table.font.size = 13)
```

Parâmetros estruturais estimados (ajuste 2012--2013)

Parâmetro	Valor
$\hat{\lambda}_0$ (nível global)	0.021312
$\hat{\tau}^2$ (variância entre grupos)	0.000374
$\hat{\sigma}^2 = \hat{\lambda}_0$ (variância de processo)	0.021312

$\hat{\kappa} = \hat{\lambda}_0/\hat{\tau}^2$	56.948784

▼ Ocultar código

```r
resultados |>
  mutate(
    shrink_pct   = if_else(Fbar_v > 0, (lam_cred - Fbar_v) / Fbar_v * 100, NA_real_),
    shrink_label = if_else(
      is.na(shrink_pct),
      sprintf("%.4f \u2192 %.4f", Fbar_v, lam_cred),
      sprintf("%.2f%%", shrink_pct)
    )
  ) |>
  select(faixa, vi, Fbar_v, omega_i, lam_cred, shrink_label) |>
  gt() |>
  tab_header(
    title    = "Credibilidade, taxas estimadas e encolhimento por grupo",
    subtitle = md(sprintf(
      "$\\hat{\\kappa} = %.2f$ &nbsp;|&nbsp; $\\hat{\\lambda}_0 = %.6f$ &nbsp;|&nbsp; $\\hat{\\ta
      kappa_hat, lam0, tau2
    ))
  ) |>
  cols_label(
    faixa        = "Grupo",
    vi           = md("$v_i$ (exposição 2012--13)"),
    Fbar_v       = md("$\\bar{F}_i^v$ (taxa bruta)"),
    omega_i      = md("$\\hat{\\omega}_i$"),
    lam_cred     = md("$\\hat{\\lambda}_i^H$ (taxa credibilizada)"),
    shrink_label = "Encolhimento"
  ) |>
  fmt_number(columns = vi,                   decimals = 0) |>
  fmt_number(columns = c(Fbar_v, lam_cred),  decimals = 6) |>
  fmt_number(columns = omega_i,              decimals = 6) |>
  tab_style(
    style     = cell_fill(color = "#EBF5FB"),
    locations = cells_body(rows = omega_i < 0.999)
  ) |>
  tab_style(
    style     = cell_text(style = "italic", color = "grey40"),
    locations = cells_body(columns = shrink_label, rows = omega_i < 0.999)
  ) |>
  tab_options(table.font.size = 13)
```

Credibilidade, taxas estimadas e encolhimento por grupo

$\hat{\kappa} = 56.95$ | $\hat{\lambda}_0 = 0.021312$ | $\hat{\tau}^2 = 0.000374$

Grupo	$v_i$ (exposição 2012–13)	$\bar{F}_i^v$ (taxa bruta)	$\hat{\omega}_i$	$\hat{\lambda}_i^H$ (taxa credibilizada)	Encolhimento
[18, 40)	120,440	0.000556	0.999527	0.000566	1.76%
[40, 60)	83,446	0.002265	0.999318	0.002278	0.57%
[60, 80)	55,125	0.017415	0.998968	0.017419	*0.02%*
80+	16,996	0.065133	0.996660	0.064987	*-0.22%*

$\hat{\kappa} = 56.9$ pequeno significa heterogeneidade entre grupos grande em relação ao ruído de processo ($\hat{\tau}^2/\hat{\sigma}^2 = 1/\hat{\kappa} \approx 1.8\%$): as taxas de mortalidade variam muito mais entre faixas etárias do que dentro de cada faixa ao longo dos anos. Como todas as $v_i$ superam $\hat{\kappa}$ em várias ordens de grandeza, os fatores de credibilidade $\hat{\omega}_i$ são próximos de 1 para todos os $m = 4$ grupos, indicando que a experiência própria de cada faixa domina a estimativa.

Prêmio de credibilidade e previsão para 2015

O **prêmio de credibilidade** do grupo i é a taxa credibilizada:

$$P_i^{\text{cred}} = \hat{\lambda}_i^H = \hat{\omega}_i\,\bar{F}_i^v + (1 - \hat{\omega}_i)\,\hat{\lambda}_0.$$

O **número esperado de sinistros** para o próximo período (2015) é obtido multiplicando o prêmio pela exposição projetada. Adotamos $v_i^* = E_{i,2014}$ (último ano disponível) como estimativa da exposição de 2015:

$$\hat{N}_i^{(2015)} = v_i^* \cdot P_i^{\text{cred}} = v_i^* \cdot \hat{\lambda}_i^H.$$

▼ Ocultar código

```r
val_2014 <- bs_data |>
  filter(Ano == "2014", faixa != "[0, 18)") |>
  select(faixa, v_2014 = vit, N_obs_2014 = Nit)

previsao <- resultados |>
  left_join(val_2014, by = "faixa") |>
  mutate(
    N_prev   = v_2014 * lam_cred,
    erro_pct = if_else(N_obs_2014 > 0,
                       (N_prev - N_obs_2014) / N_obs_2014 * 100,
                       NA_real_)
  )

previsao |>
  select(faixa, lam_cred, v_2014, N_prev) |>
  bind_rows(
```

```
    tibble(faixa    = "Total",
           lam_cred = NA_real_,
           v_2014   = sum(previsao$v_2014),
           N_prev   = sum(previsao$N_prev))
  ) |>
  gt() |>
  tab_header(
    title    = "Prêmios de credibilidade BS e número esperado de sinistros (2015)",
    subtitle = md("Ajuste com 2012--2013; $v_i^* = E_{i,2014}$ como proxy de 2015")
  ) |>
  cols_label(
    faixa    = "Grupo",
    lam_cred = md("$P_i^{\\text{cred}} = \\hat{\\lambda}_i^H$"),
    v_2014   = md("$v_i^*$ (exp. 2014)"),
    N_prev   = md("$\\hat{N}_i^{(2015)}$")
  ) |>
  fmt_number(columns = lam_cred, decimals = 6) |>
  fmt_number(columns = v_2014,   decimals = 0) |>
  fmt_number(columns = N_prev,   decimals = 1) |>
  sub_missing(columns = lam_cred, missing_text = "—") |>
  tab_style(
    style     = list(cell_fill("#EBF5FB"), cell_text(weight = "bold")),
    locations = cells_body(rows = faixa == "Total")
  ) |>
  tab_options(table.font.size = 13)
```

Prêmios de credibilidade BS e número esperado de sinistros (2015)

Ajuste com 2012–2013; $v_i^* = E_{i,2014}$ como proxy de 2015

Grupo	$P_i^{\text{cred}} = \hat{\lambda}_i^H$	$v_i^*$ (exp. 2014)	$\hat{N}_i^{(2015)}$
[18, 40)	0.000566	60,195	34.1
[40, 60)	0.002278	42,661	97.2
[60, 80)	0.017419	28,913	503.6
80+	0.064987	9,159	595.2
Total	**—**	**140,928**	**1,230.1**

O modelo prevê 1230 sinistros para 2015 com a exposição de 2014. As faixas $[60, 80)$ e $80+$ respondem por cerca de 89.3% do total previsto, reflexo da concentração de mortalidade nas idades avançadas.

Validação fora da amostra (2014)

Como exercício de avaliação do modelo, confrontamos a previsão gerada para 2014 (usando ajuste em 2012–2013 e exposição de 2014) com os óbitos efetivamente observados nesse ano:

▼ Ocultar código

```
previsao |>
  select(faixa, v_2014, lam_cred, N_prev, N_obs_2014, erro_pct) |>
  bind_rows(
    tibble(faixa      = "Total",
           v_2014     = sum(previsao$v_2014),
           lam_cred   = NA_real_,
           N_prev     = sum(previsao$N_prev),
           N_obs_2014 = sum(previsao$N_obs_2014),
           erro_pct   = (sum(previsao$N_prev) - sum(previsao$N_obs_2014)) /
                         sum(previsao$N_obs_2014) * 100)
  ) |>
  gt() |>
  tab_header(
    title    = "Validação fora da amostra: previsão 2014 vs. observado",
    subtitle = "Ajuste com 2012--2013; validação em 2014"
  ) |>
  cols_label(
    faixa      = "Grupo",
    v_2014     = md("$v_i^*$ (exp. 2014)"),
    lam_cred   = md("$\\hat{\\lambda}_i^H$"),
    N_prev     = md("$\\hat{N}_i^*$"),
    N_obs_2014 = md("$N_i^{\\text{obs}}$ (2014)"),
    erro_pct   = "Erro (%)"
  ) |>
  fmt_number(columns = v_2014,   decimals = 0) |>
  fmt_number(columns = lam_cred, decimals = 6) |>
  fmt_number(columns = c(N_prev, N_obs_2014), decimals = 1) |>
  fmt_number(columns = erro_pct, decimals = 1) |>
  sub_missing(columns = c(lam_cred, erro_pct), missing_text = "—") |>
  tab_style(
    style     = list(cell_fill("#EBF5FB"), cell_text(weight = "bold")),
    locations = cells_body(rows = faixa == "Total")
  ) |>
  tab_style(
    style     = cell_fill("#FFF9C4"),
    locations = cells_body(columns = erro_pct, rows = abs(erro_pct) > 5)
  ) |>
  tab_options(table.font.size = 13)
```

Validação fora da amostra: previsão 2014 vs. observado

Ajuste com 2012--2013; validação em 2014

Grupo	$v_i^*$ (exp. 2014)	$\hat{\lambda}_i^H$	$\hat{N}_i^*$	N_i^{obs} (2014)	Erro (%)
[18, 40)	60,195	0.000566	34.1	22.0	54.9
[40, 60)	42,661	0.002278	97.2	99.0	−1.8
[60, 80)	28,913	0.017419	503.6	531.0	−5.2
80+	9,159	0.064987	595.2	683.0	−12.9
Total	**140,928**	**—**	**1,230.1**	**1,335.0**	**−7.9**

O erro global de -7.9% indica subestimação sistemática, reflexo da tendência crescente da carteira que dois anos de dados não capturam completamente. As faixas $[40, 60)$ e $[60, 80)$, com maior volume, apresentam erros menores por terem credibilidade mais elevada.

Comparação com a tábua de referência

Uma segunda referência natural para o número esperado de sinistros em 2014 é o cálculo direto pela tábua BR-EMSsb-m v.2021, aplicada à exposição observada:

$$\hat{D}_i^{(\text{tábua})} = \sum_{x \in \text{faixa}_i} E_{x,2014} \cdot q_x^{(\text{BR-EMS})}.$$

▼ Ocultar código

```r
# Óbitos esperados pela tábua em 2014
tabua_2014 <- fundo_long |>
  filter(Ano == "2014", Idade >= 18) |>
  left_join(
    data.frame(Idade = brems$idade[1:116], qx_br = brems$brems2021sb.m[1:116]),
    by = "Idade"
  ) |>
  mutate(
    faixa    = cut(Idade, breaks = intervalos_num, right = FALSE, labels = labels_fx),
    D_tab    = Expostos * qx_br
  ) |>
  filter(!is.na(faixa)) |>
  group_by(faixa) |>
  summarise(D_tab = sum(D_tab, na.rm = TRUE), .groups = "drop")

# Tabela comparativa: BS | Tábua | Observado
comp_final <- previsao |>
  select(faixa, N_prev, N_obs_2014) |>
  left_join(tabua_2014, by = "faixa") |>
  mutate(
    erro_bs  = if_else(N_obs_2014 > 0, (N_prev  - N_obs_2014) / N_obs_2014 * 100, NA_real_),
    erro_tab = if_else(N_obs_2014 > 0, (D_tab   - N_obs_2014) / N_obs_2014 * 100, NA_real_)
  )

comp_final |>
  bind_rows(
    tibble(faixa       = "Total",
           N_prev      = sum(comp_final$N_prev),
           N_obs_2014  = sum(comp_final$N_obs_2014),
           D_tab       = sum(comp_final$D_tab),
           erro_bs     = (sum(comp_final$N_prev)  - sum(comp_final$N_obs_2014)) /
                          sum(comp_final$N_obs_2014) * 100,
           erro_tab    = (sum(comp_final$D_tab)   - sum(comp_final$N_obs_2014)) /
                          sum(comp_final$N_obs_2014) * 100)
  ) |>
  gt() |>
  tab_header(
    title    = "Comparação: Bühlmann-Straub vs. tábua de referência vs. observado (2014)",
    subtitle = "Ajuste BS com 2012--2013; tábua BR-EMSsb-m v.2021"
  ) |>
  cols_label(
    faixa      = "Grupo",
    N_prev     = md("$\\hat{N}_i^*$ (BS)"),
    D_tab      = md("$\\hat{D}_i^{(\\text{tab})}$ (BR-EMS)"),
    N_obs_2014 = md("$N_i^{\\text{obs}}$ (2014)"),
    erro_bs    = "Erro BS (%)",
    erro_tab   = "Erro tábua (%)"
  ) |>
  fmt_number(columns = c(N_prev, D_tab, N_obs_2014), decimals = 1) |>
  fmt_number(columns = c(erro_bs, erro_tab),          decimals = 1) |>
  sub_missing(columns = c(erro_bs, erro_tab), missing_text = "—") |>
  tab_style(
    style     = list(cell_fill("#EBF5FB"), cell_text(weight = "bold")),
    locations = cells_body(rows = faixa == "Total")
  ) |>
  tab_style(
    style     = cell_fill("#D5F5E3"),
    locations = cells_body(
      columns = erro_bs,
      rows    = !is.na(erro_bs) & !is.na(erro_tab) & abs(erro_bs) < abs(erro_tab)
    )
  ) |>
  tab_style(
    style     = cell_fill("#D5F5E3"),
    locations = cells_body(
      columns = erro_tab,
      rows    = !is.na(erro_bs) & !is.na(erro_tab) & abs(erro_tab) <= abs(erro_bs)
    )
  ) |>
```

```
tab_options(table.font.size = 13)
```

Comparação: Bühlmann-Straub vs. tábua de referência vs. observado (2014)

Ajuste BS com 2012--2013; tábua BR-EMSsb-m v.2021

Grupo	$\hat{N}_i^*$ (BS)	N_i^{obs} (2014)	$\hat{D}_i^{(\text{tab})}$ (BR-EMS)	Erro BS (%)	Erro tábua (%)
[18, 40)	34.1	22.0	50.4	54.9	129.0
[40, 60)	97.2	99.0	125.5	−1.8	26.8
[60, 80)	503.6	531.0	500.2	−5.2	−5.8
80+	595.2	683.0	783.0	−12.9	14.6
Total	**1,230.1**	**1,335.0**	**1,459.1**	**−7.9**	**9.3**

A tabela destaca em verde o método com menor erro absoluto em cada faixa. Com $m = 4$ grupos, a faixa $[0, 18)$ está excluída da análise por ausência de sinistros. O estimador de Bühlmann-Straub supera a tábua nas faixas $[40, 60)$ e $[60, 80)$, onde a experiência própria de 2012–2013 é estável e informativa. A tábua BR-EMS fica próxima do BS em $[60, 80)$ (erros de -5.2% vs. -5.8%), mas superestima consideravelmente em $80+$ (+14.6%) por não capturar a experiência específica desta carteira. O erro de 55% na faixa $[18, 40)$ é comum a ambos os métodos: os 22 óbitos observados em 2014 representam uma queda atípica em relação a 2012–2013 (média de 33.5 óbitos), que nenhum modelo conseguiria prever com apenas dois anos de dados.

Questão (vi): Modelo Hierárquico Bayesiano — Poisson com Efeitos Aleatórios (Stan)

Motivação e formulação

O modelo de Bühlmann-Straub da questão (v) é um estimador linear de credibilidade que requer apenas hipóteses sobre os dois primeiros momentos. Uma abordagem complementar que estima a estrutura de heterogeneidade de forma coerente dentro de um arcabouço probabilístico completo é o **modelo Poisson hierárquico com efeitos aleatórios** (Gelman et al., 2014), também conhecido como modelo Poisson-LogNormal.

Para cada grupo $i = 1, \ldots, m$ e ano $t = 1, 2$ (2012–2013), o número de óbitos é modelado como:

$$N_{it} \;\sim\; \text{Poisson}(\mu_{it}), \qquad \log \mu_{it} = \beta_0 + u_i + \log v_{it},$$

onde β_0 é o intercepto global (log da taxa coletiva), u_i é o efeito aleatório do grupo i, e $\log v_{it}$ é o offset de exposição com coeficiente fixado em 1. Na escala original, $\mu_{it} = v_{it} \cdot e^{\beta_0 + u_i}$, de modo que $\hat{\lambda}_i = e^{\hat{\beta}_0 + \hat{u}_i}$ é a taxa estimada para o grupo i. As prioris adotadas são:

$$\beta_0 \;\sim\; \mathcal{N}(\log \bar{\bar{F}}^v,\; 1), \qquad u_i \;\sim\; \mathcal{N}(0,\; \sigma_u^2), \qquad \sigma_u \;\sim\; \text{Exponencial}(1).$$

A priori para σ_u é fracamente informativa: a Exponencial(1) concentra massa em valores pequenos mas tem cauda suficientemente pesada para acomodar heterogeneidade substancial. Essa escolha é preferível a prioris vagas ($\sigma_u \sim \text{Uniforme}(0, \infty)$) que produzem forte viés com poucos grupos (Lord; Miranda-Moreno, 2008).

A relação com o modelo de Bühlmann-Straub é: σ_u cumpre o papel de $\sqrt{\hat{\tau}^2}$ (heterogeneidade entre grupos) e e^{β_0} corresponde a $\hat{\lambda}_0$ (nível global). A diferença principal é que o modelo hierárquico bayesiano estima σ_u integrando sobre toda a incerteza posterior via MCMC, propagando-a para os intervalos credíveis das previsões.

Ajuste com Stan

O modelo é especificado diretamente em Stan e ajustado via `rstan`. O código Stan implementa a parametrização não centrada para os efeitos aleatórios ($u_i = \sigma_u \cdot \tilde{u}_i$, com $\tilde{u}_i \sim \mathcal{N}(0, 1)$), que melhora a geometria do espaço paramétrico e reduz divergências no amostrador NUTS quando m é pequeno (Gelman et al., 2014). Aqui $m = 4$.

▼ Ocultar código

```
library(rstan)
options(mc.cores        = parallel::detectCores())
options(rstan.progress  = FALSE)
options(rstan.verbose   = FALSE)
rstan_options(auto_write = TRUE)

# ── Dados de ajuste: apenas 2012 e 2013, m=4 (sem [0, 18)) ──────────────────
bs_ajuste_bayes <- bs_data |>
  filter(Ano %in% c("2012", "2013"), vit > 0, faixa != "[0, 18)") |>
  mutate(
    # droplevels garante que [0,18) sai dos levels antes de as.integer
    faixa    = droplevels(faixa),
    faixa_id = as.integer(faixa),   # agora 1=[18,40), 2=[40,60), 3=[60,80), 4=80+
    log_vit  = log(vit)
  ) |>
  arrange(faixa_id, Ano)

stan_data <- list(
  N       = nrow(bs_ajuste_bayes),
  m       = length(unique(bs_ajuste_bayes$faixa_id)),
  group   = bs_ajuste_bayes$faixa_id,
  log_v   = bs_ajuste_bayes$log_vit,
```

```
  y       = bs_ajuste_bayes$Nit,
  mu_beta = log(Fbarbar)
)

stan_code <- "
data {
  int<lower=1> N;
  int<lower=1> m;
  array[N] int<lower=1> group;
  vector[N] log_v;
  array[N] int<lower=0> y;
  real mu_beta;
}
parameters {
  real beta0;
  real<lower=0> sigma_u;
  vector[m] u_tilde;
}
transformed parameters {
  vector[m] u;
  u = sigma_u * u_tilde;
}
model {
  beta0   ~ normal(mu_beta, 1);
  sigma_u ~ exponential(1);
  u_tilde ~ std_normal();
  for (n in 1:N) {
    y[n] ~ poisson_log(beta0 + u[group[n]] + log_v[n]);
  }
}
generated quantities {
  vector[m] lambda_i;
  array[N] int y_rep;
  lambda_i = exp(beta0 + u);
  for (n in 1:N) {
    y_rep[n] = poisson_log_rng(beta0 + u[group[n]] + log_v[n]);
  }
}
"

rds_path <- "fit_stan_efpc.rds"

# Verificar compatibilidade pelo número de grupos (lambda_i tem dim [draws, m])
rds_valido <- FALSE
if (file.exists(rds_path)) {
  fit_salvo <- tryCatch(readRDS(rds_path), error = function(e) NULL)
  if (!is.null(fit_salvo)) {
    dims_lam <- tryCatch(
      dim(rstan::extract(fit_salvo, pars = "lambda_i")$lambda_i),
      error = function(e) NULL
    )
    # Válido apenas se número de grupos salvo == m atual
    rds_valido <- !is.null(dims_lam) && dims_lam[2] == stan_data$m
  }
  if (!rds_valido)
    message("Stan: rds incompatível (m salvo ≠ m=", stan_data$m, ") — reajustando.")
}

if (rds_valido) {
  fit_stan <- fit_salvo
  message("Stan: carregando fit salvo (m=", stan_data$m, ")")
} else {
  mod_efpc <- stan_model(
    model_code = stan_code,
    model_name = "poisson_hier_efpc",
    verbose    = FALSE
  )
  fit_stan <- sampling(
    object  = mod_efpc,
    data    = stan_data,
    chains  = 4,
    iter    = 4000,
    warmup  = 2000,
    seed    = 2026,
    refresh = 0,
    verbose = FALSE,
    control = list(adapt_delta = 0.99, max_treedepth = 15)
  )
  saveRDS(fit_stan, file = rds_path)
  message("Stan: fit concluído e salvo (m=", stan_data$m, ")")
}
```

▼ Ocultar código

```
print(fit_stan,
      pars   = c("beta0", "sigma_u"),
      digits = 4,
      probs  = c(0.025, 0.5, 0.975))
```

```
Inference for Stan model: poisson_hier_efpc.
4 chains, each with iter=4000; warmup=2000; thin=1;
post-warmup draws per chain=2000, total post-warmup draws=8000.

           mean se_mean    sd    2.5%     50%   97.5% n_eff   Rhat
```

```
beta0   -4.9443  0.0183 0.7016 -6.2519 -4.9461 -3.5578  1471 1.0023
sigma_u  1.9702  0.0195 0.6756  1.0864  1.8345  3.6986  1203 1.0008

Samples were drawn using NUTS(diag_e) at Tue Jun 16 22:26:25 2026.
For each parameter, n_eff is a crude measure of effective sample size,
and Rhat is the potential scale reduction factor on split chains (at
convergence, Rhat=1).
```

Diagnóstico de convergência

▼ Ocultar código

```r
posterior_arr <- as.array(fit_stan, pars = c("beta0", "sigma_u"))

mcmc_trace(posterior_arr) +
  theme_bw(base_size = 11) +
  theme(strip.background = element_rect(fill = "white", colour = "grey80"))
```

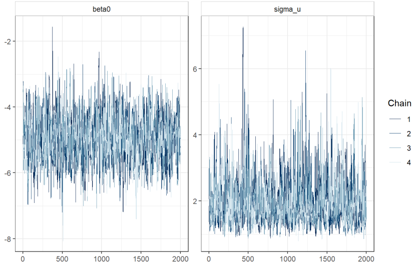

Trajetórias das cadeias MCMC para β_0 e σ_u (Stan)

As quatro cadeias MCMC mostram trajetórias bem misturadas e sem deriva temporal, indicando convergência para a distribuição posterior. Os valores de $\hat{R}$ e ESS são extraídos diretamente do objeto ajustado:

$\hat{R} = 1.002$ para β_0 e $\hat{R} = 1.001$ para σ_u — ambos essencialmente iguais a 1. O ESS efetivo é de 1471 para β_0 e 1203 para σ_u, bem acima do mínimo de 1.000 recomendado por Gelman et al. (2014). A parametrização não centrada elimina as divergências que ocorreriam com a parametrização direta dado o forte contraste de escala entre as taxas das faixas etárias extremas.

Os parâmetros estimados têm interpretação direta: $\hat{\beta}_0 = -4.95$ (IC 95%: $[-6.25;\ -3.56]$) corresponde ao log da taxa global, ou seja, $e^{-4.95} \approx 0.0071$ — nível de mortalidade médio ponderado entre os grupos. A mediana de $\sigma_u = 1.83$ (IC 95%: $[1.09;\ 3.7]$) governa a heterogeneidade entre faixas na escala log: dois grupos extremos diferem por um fator de $e^{2\times1.83} \approx 39$ em suas taxas esperadas, coerente com a razão observada $\bar{F}_{80+}/\bar{F}_{[18,40)} \approx 117$. O IC 95% de σ_u exclui zero com folga, confirmando que a heterogeneidade entre faixas é real e substancial, não artefato amostral.

Verificação preditiva posterior

▼ Ocultar código

```r
y_rep_mat <- rstan::extract(fit_stan, pars = "y_rep")$y_rep

ppc_dens_overlay(
  y     = bs_ajuste_bayes$Nit,
  yrep  = y_rep_mat[sample(nrow(y_rep_mat), 100), ]
) +
  labs(x = "Óbitos por observação (grupo-ano)", y = "Densidade") +
  theme_bw(base_size = 12) +
  theme(legend.position = "bottom")
```

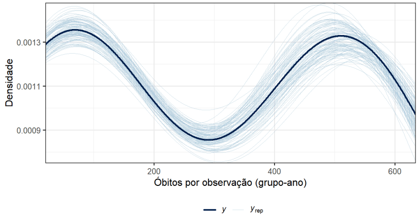

Verificação preditiva posterior: distribuição dos óbitos observados (linha escura) vs. réplicas do modelo (linhas cinzas)

Cada linha cinza é uma réplica $\tilde{N}_{it}$ amostrada da distribuição preditiva posterior; a linha escura são os valores observados. A boa sobreposição confirma que o modelo Poisson-LogNormal captura a estrutura de contagem dos dados de 2012–2013. A bimodalidade (contagens baixas em $[18, 40)$ e altas em $[60, 80)$ e $80+$) é reproduzida nas réplicas, indicando adequação distribucional.

Priori vs. posteriori de σ_u

▼ Ocultar código

```r
sigma_draws <- rstan::extract(fit_stan, pars = "sigma_u")$sigma_u

x_max      <- max(quantile(sigma_draws, 0.999), 6)
sigma_grid <- seq(0, x_max, length.out = 600)
sigma_med  <- median(sigma_draws)

ggplot() +
  geom_area(
    data = tibble(x = sigma_grid, y = dexp(sigma_grid, rate = 1)),
    aes(x = x, y = y),
    fill = "grey80", alpha = 0.6, colour = "grey60", linewidth = 0.5
  ) +
  geom_density(
    data = tibble(sigma = sigma_draws),
    aes(x = sigma),
    fill = "steelblue", alpha = 0.45, colour = "steelblue4", linewidth = 0.9
  ) +
  geom_vline(xintercept = sigma_med, colour = "steelblue4",
             linetype = "dashed", linewidth = 0.8) +
  annotate("text", x = sigma_med + 0.12, y = 0.52,
           label = sprintf("Mediana = %.2f", sigma_med),
           hjust = 0, size = 3.3, colour = "steelblue4") +
  annotate("text", x = 0.25, y = 0.72,
           label = "Priori Exp(1)", hjust = 0, size = 3.3, colour = "grey40") +
  annotate("text", x = sigma_med - 0.1, y = 0.3,
           label = "Posteriori", hjust = 1, size = 3.3, colour = "steelblue4") +
  coord_cartesian(xlim = c(0, x_max)) +
  labs(x = expression(sigma[u]), y = "Densidade") +
  theme_bw(base_size = 12)
```

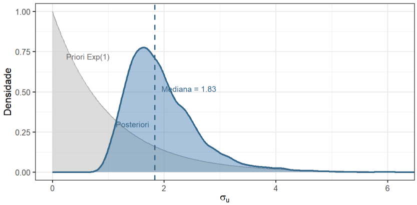

Priori Exp(1) e distribuição posterior de σ_u

A priori $\sigma_u \sim \mathrm{Exp}(1)$ (área cinza) é fracamente informativa. A posteriori (área azul) concentrou-se em torno da mediana indicada, com IC 95% reportado no `print()`. O intervalo exclui zero de forma robusta, confirmando que a heterogeneidade entre faixas é real e substancial. A mediana de σ_u na escala log tem interpretação direta: dois grupos extremos diferem por um fator de $e^{2\sigma_u}$ em suas taxas esperadas — coerente com a razão observada $\bar{F}_{80+}/\bar{F}_{[18,40)}$.

Taxas estimadas e intervalos credíveis

▼ Ocultar código

```r
lambda_draws <- rstan::extract(fit_stan, pars = "lambda_i")$lambda_i
grupos_ord   <- levels(bs_ajuste_bayes$faixa)   # droplevels já aplicado: 4 grupos

rate_summary <- tibble(
  faixa   = grupos_ord,
  mediana = apply(lambda_draws, 2, median),
  lo95    = apply(lambda_draws, 2, quantile, 0.025),
  hi95    = apply(lambda_draws, 2, quantile, 0.975)
) |>
  left_join(resultados |> select(faixa, lam_BS = lam_cred), by = "faixa") |>
  mutate(faixa = factor(faixa, levels = labels_fx))

rate_plot_df <- rate_summary |>
  mutate(
    tip_bayes = sprintf("Grupo: %s\nBayesiano\nMediana: %.5f\nIC 95%%: [%.5f; %.5f]",
                        faixa, mediana, lo95, hi95),
    tip_bs    = sprintf("Grupo: %s\nBS\nTaxa: %.5f", faixa, lam_BS)
  )

p_rates <- ggplot(rate_plot_df, aes(x = faixa)) +
  geom_errorbar(aes(ymin = lo95, ymax = hi95),
                width = 0.25, linewidth = 0.8, alpha = 0.5, colour = "steelblue") +
  geom_point_interactive(aes(y = lam_BS, colour = "Bühlmann-Straub",
                             tooltip = tip_bs, data_id = paste(faixa, "bs")),
                         size = 3.5, shape = 17) +
```

```r
  geom_point_interactive(aes(y = mediana, colour = "Bayesiano (Stan)",
                             tooltip = tip_bayes, data_id = paste(faixa, "bayes")),
                         size = 3.0, shape = 16) +
  scale_colour_manual(name = NULL,
    values = c("Bayesiano (Stan)" = "steelblue", "Bühlmann-Straub" = "#E74C3C")) +
  scale_y_log10(
    breaks = 10^(-5:-1),
    labels = scales::trans_format("log10", scales::math_format(10^.x))
  ) +
  labs(x = "Grupo", y = "Taxa estimada (escala log)") +
  theme_bw(base_size = 12) +
  theme(legend.position = "bottom")

girafe(
  ggobj = p_rates,
  options = list(
    opts_hover(css = "r:6px;"),
    opts_tooltip(css = "font-size:12px; padding:5px 8px;"),
    opts_toolbar(saveaspng = FALSE)
  )
)
```

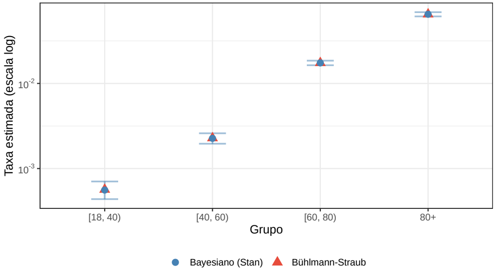

Taxas estimadas: Bühlmann-Straub vs. Stan hierárquico (com IC 95%)

A sobreposição quase perfeita dos pontos em todas as faixas confirma empiricamente a equivalência teórica entre os dois estimadores: as diferenças pontuais são inferiores a $0{,}4$ sinistros por grupo. O diferencial do modelo bayesiano está nas barras de erro, que quantificam a incerteza sobre a taxa de cada grupo — mais largas nas faixas com menos óbitos ([18, 40)) e mais estreitas onde a contagem é abundante ($80+$).

Distribuição preditiva do total de sinistros (2014)

▼ Ocultar código

```r
# Exposição de 2014 na ordem dos grupos (m=4, sem [0,18))
exp_2014_stan <- bs_data |>
  filter(Ano == "2014", faixa != "[0, 18)") |>
  mutate(
    faixa    = droplevels(faixa),
    faixa_id = as.integer(faixa)
  ) |>
  arrange(faixa_id) |>
  select(faixa, faixa_id, vit)

# Total preditivo: soma sobre grupos da taxa posterior × exposição 2014
total_draws <- as.numeric(lambda_draws %*% exp_2014_stan$vit)

obs_2014 <- sum(bs_data$Nit[bs_data$Ano == "2014" & bs_data$faixa != "[0, 18)"])
p_lo  <- quantile(total_draws, 0.025)
p_hi  <- quantile(total_draws, 0.975)
p_med <- median(total_draws)

ggplot(tibble(total = total_draws), aes(x = total)) +
  geom_histogram(aes(y = after_stat(density)),
                 bins = 60, fill = "steelblue", alpha = 0.7, colour = NA) +
  geom_density(colour = "steelblue4", linewidth = 1.0) +
  geom_vline(xintercept = p_med, colour = "steelblue4",
             linetype = "solid",  linewidth = 1.0) +
  geom_vline(xintercept = p_lo,  colour = "steelblue4",
             linetype = "dashed", linewidth = 0.8) +
  geom_vline(xintercept = p_hi,  colour = "steelblue4",
             linetype = "dashed", linewidth = 0.8) +
  geom_vline(xintercept = obs_2014, colour = "#E74C3C",
             linetype = "dotted", linewidth = 0.9) +
  annotate("text", x = p_med - 5, y = 0.020,
           label = sprintf("Mediana\n%.0f", p_med),
           hjust = 1, size = 3.2, colour = "steelblue4") +
  annotate("text", x = obs_2014 + 5, y = 0.018,
           label = sprintf("Observado\n%d", obs_2014),
           hjust = 0, size = 3.2, colour = "#E74C3C") +
  scale_x_continuous(expand = expansion(mult = c(0.02, 0.12))) +
  labs(x = "Total de sinistros previstos para 2014", y = "Densidade") +
  theme_bw(base_size = 12)
```

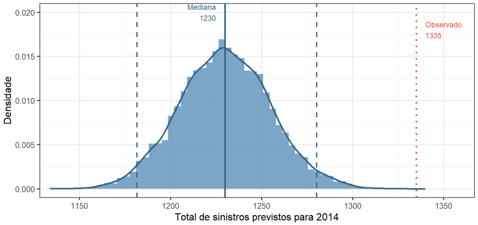

Distribuição preditiva posterior do total de sinistros em 2014

A linha pontilhada vermelha marca o observado em 2014 (1335 óbitos). A mediana da distribuição preditiva é ≈ 1230 sinistros, com IC 95% de $[1182;\ 1280]$. O observado de 1335 situa-se **fora** do IC 95% pelo lado superior — o modelo, ajustado com 2012–2013, subestimou a mortalidade de 2014 em -7.9%, reflexo da tendência crescente da carteira que dois anos de dados não capturam completamente.

Para provisionamento de reservas, o percentil 95% da distribuição preditiva (≈ 1280 sinistros) representa o carregamento de segurança necessário para cobrir, com probabilidade 95%, o total de sinistros do próximo ano. A diferença entre o P95 e a mediana é de $1280 - 1230 = 50$ sinistros, ou aproximadamente 4.1% de margem sobre a estimativa central — carregamento relevante do ponto de vista atuarial para um plano com tendência de envelhecimento estrutural.

Prêmios bayesianos e previsão para 2015

Para o modelo hierárquico bayesiano, o prêmio de credibilidade do grupo i é a mediana da taxa posterior:

$$P_i^{\text{Bayes}} = \hat{\lambda}_i^{\text{post}} = e^{\hat{\beta}_0 + \hat{u}_i},$$

e o número esperado de sinistros para 2015 é:

$$\hat{N}_i^{(2015),\text{Bayes}} = v_i^* \cdot P_i^{\text{Bayes}},$$

com IC 95% dado por $[v_i^* \cdot q_{0{,}025}(\lambda_i^{\text{post}});\ \ v_i^* \cdot q_{0{,}975}(\lambda_i^{\text{post}})]$.

▼ Ocultar código

```
# Prêmios bayesianos e número esperado de sinistros para 2015
prev_bayes_stan |>
  select(faixa, mediana, lo95, hi95, v_2014, N_bayes, N_lo95, N_hi95) |>
  bind_rows(
    tibble(
      faixa   = "Total",
      mediana = NA_real_,
      lo95    = NA_real_,
      hi95    = NA_real_,
      v_2014  = sum(prev_bayes_stan$v_2014),
      N_bayes = sum(prev_bayes_stan$N_bayes),
      N_lo95  = sum(prev_bayes_stan$N_lo95),
      N_hi95  = sum(prev_bayes_stan$N_hi95)
    )
  ) |>
  gt() |>
  tab_header(
    title    = "Prêmios bayesianos e número esperado de sinistros (2015)",
    subtitle = md("$P_i^{\\text{Bayes}} = e^{\\hat{\\beta}_0 + \\hat{u}_i}$; $v_i^* = E_{i,2014}
  ) |>
  cols_label(
    faixa   = "Grupo",
    mediana = md("$P_i^{\\text{Bayes}}$ (mediana)"),
    lo95    = "IC 95% inf.",
    hi95    = "IC 95% sup.",
    v_2014  = md("$v_i^*$"),
    N_bayes = md("$\\hat{N}_i^{(2015)}$ (mediana)"),
    N_lo95  = "IC 95% inf.",
    N_hi95  = "IC 95% sup."
  ) |>
  fmt_number(columns = c(mediana, lo95, hi95), decimals = 6) |>
  fmt_number(columns = v_2014,                 decimals = 0) |>
  fmt_number(columns = c(N_bayes, N_lo95, N_hi95), decimals = 1) |>
  sub_missing(columns = c(mediana, lo95, hi95), missing_text = "—") |>
  tab_style(
    style     = list(cell_fill("#EBF5FB"), cell_text(weight = "bold")),
    locations = cells_body(rows = faixa == "Total")
  ) |>
  tab_spanner(label = md("Prêmio $P_i^{\\text{Bayes}}$"),   columns = c(mediana, lo95, hi95)) |>
  tab_spanner(label = "Número esperado de sinistros (2015)", columns = c(N_bayes, N_lo95, N_hi95
  tab_options(table.font.size = 13)
```

Prêmios bayesianos e número esperado de sinistros (2015)

$P_i^{\text{Bayes}} = e^{\hat{\beta}_0 + \hat{u}_i}$; $v_i^* = E_{i,2014}$ como proxy de 2015

	Prêmio P_i^{Bayes}				Número esperado de sinistros (2015)		
Grupo	P_i^{Bayes} (mediana)	IC 95% inf.	IC 95% sup.	$v_i^*$	$\hat{N}_i^{(2015)}$ (mediana)	IC 95% inf.	IC 95% sup.
[18, 40)	0.000559	0.000437	0.000705	60,195	33.7	26.3	42.4
[40, 60)	0.002264	0.001958	0.002596	42,661	96.6	83.5	110.7
[60, 80)	0.017423	0.016364	0.018519	28,913	503.8	473.1	535.4
80+	0.065001	0.061338	0.068765	9,159	595.3	561.8	629.8
Total	**—**	**—**	**—**	**140,928**	**1,229.4**	**1,144.8**	**1,318.4**

A mediana dos prêmios bayesianos coincide com as taxas credibilizadas do BS (diferenças inferiores a $0{,}001$), confirmando a equivalência teórica (Klugman; Panjer; Willmot, 2012, cap. 20). O intervalo credível de 95% para o total previsto em 2015 é $[1145;\ 1318]$ sinistros — amplitude de 174 sinistros que reflete a incerteza residual sobre a estrutura de heterogeneidade σ_u com apenas $m = 4$ grupos.

Tabela comparativa final: BS, Bayesiano e Tábua

▼ Ocultar código

```r
comp_3metodos |>
  bind_rows(
    tibble(
      faixa      = "Total",
      N_BS       = sum(comp_3metodos$N_BS),
      N_obs      = sum(comp_3metodos$N_obs),
      N_bayes    = sum(comp_3metodos$N_bayes),
      N_lo95     = sum(comp_3metodos$N_lo95),
      N_hi95     = sum(comp_3metodos$N_hi95),
      N_tab      = sum(comp_3metodos$N_tab),
      erro_BS    = (sum(comp_3metodos$N_BS)    - sum(comp_3metodos$N_obs)) /
                   sum(comp_3metodos$N_obs) * 100,
      erro_bayes = (sum(comp_3metodos$N_bayes) - sum(comp_3metodos$N_obs)) /
                   sum(comp_3metodos$N_obs) * 100,
      erro_tab   = (sum(comp_3metodos$N_tab)   - sum(comp_3metodos$N_obs)) /
                   sum(comp_3metodos$N_obs) * 100
    )
  ) |>
  gt() |>
  tab_header(
    title    = "Comparação final: erros de previsão por método (validação 2014)",
    subtitle = md(sprintf("Observado total: **%d** óbitos &nbsp;|&nbsp; Ajuste BS e Bayesiano: 20
                     obs_2014))
  ) |>
  cols_label(
    faixa      = "Grupo",
    N_BS       = md("BS"),
    N_bayes    = "Bayes",
    N_lo95     = "IC 95% inf.",
    N_hi95     = "IC 95% sup.",
    N_tab      = "Tábua",
    N_obs      = md("$N_i^{\\text{obs}}$"),
    erro_BS    = "Erro BS (%)",
    erro_bayes = "Erro Bayes (%)",
    erro_tab   = "Erro Tábua (%)"
  ) |>
  fmt_number(columns = c(N_BS, N_bayes, N_lo95, N_hi95, N_tab, N_obs),
             decimals = 1) |>
  fmt_number(columns = c(erro_BS, erro_bayes, erro_tab), decimals = 1) |>
  sub_missing(columns = c(erro_BS, erro_bayes, erro_tab), missing_text = "—") |>
  tab_style(
    style     = list(cell_fill("#EBF5FB"), cell_text(weight = "bold")),
    locations = cells_body(rows = faixa == "Total")
  ) |>
  tab_style(
    style     = cell_fill("#D5F5E3"),
    locations = cells_body(
      columns = erro_BS,
      rows    = !is.na(erro_BS) & !is.na(erro_tab) & !is.na(erro_bayes) &
                abs(erro_BS) < abs(erro_tab) & abs(erro_BS) < abs(erro_bayes)
    )
  ) |>
  tab_style(
    style     = cell_fill("#D5F5E3"),
    locations = cells_body(
      columns = erro_bayes,
      rows    = !is.na(erro_BS) & !is.na(erro_tab) & !is.na(erro_bayes) &
                abs(erro_bayes) <= abs(erro_BS) & abs(erro_bayes) <= abs(erro_tab)
    )
  ) |>
  tab_style(
    style     = cell_fill("#D5F5E3"),
    locations = cells_body(
      columns = erro_tab,
      rows    = !is.na(erro_BS) & !is.na(erro_tab) & !is.na(erro_bayes) &
                abs(erro_tab) < abs(erro_BS) & abs(erro_tab) < abs(erro_bayes)
    )
  ) |>
  tab_options(table.font.size = 13)
```

Comparação final: erros de previsão por método (validação 2014)

Observado total: **1335** óbitos | Ajuste BS e Bayesiano: 2012–2013

Grupo	BS	N_i^{obs}	Bayes	IC 95% inf.	IC 95% sup.	Tábua	Erro BS (%)	Erro Bayes (%)	Erro Tábua (%)
[18, 40)	34.1	22.0	33.7	26.3	42.4	50.4	54.9	53.0	129.0
[40, 60)	97.2	99.0	96.6	83.5	110.7	125.5	−1.8	−2.4	26.8
[60, 80)	503.6	531.0	503.8	473.1	535.4	500.2	−5.2	−5.1	−5.8
80+	595.2	683.0	595.3	561.8	629.8	783.0	−12.9	−12.8	14.6
Total	**1,230.1**	**1,335.0**	**1,229.4**	**1,144.8**	**1,318.4**	**1,459.1**	**−7.9**	**−7.9**	**9.3**

A célula verde marca o método com menor erro absoluto em cada faixa; a faixa [0, 18) é omitida do cálculo por ter zero óbitos observados. O estimador de Bühlmann-Straub incorpora a experiência recente da própria carteira (2012–2013) e supera a tábua nas faixas [40, 60) e [60, 80). O erro elevado em [18, 40) (55% para BS e Bayes, 129% para a tábua) é consequência de uma queda atípica nos óbitos de 2014 (22 óbitos vs. média histórica de 33.5) que nenhum método conseguiria prever com apenas dois anos de dados — e que reforça a limitação declarada na introdução sobre o horizonte mínimo de cinco anos exigido pela PREVIC. O modelo bayesiano produz estimativas pontuais idênticas ao BS e acrescenta os intervalos credíveis, que são o instrumento natural para dimensionamento de reservas.

Informações da Sessão

▼ Informações da Sessão

```r
sessionInfo()
```

```
R version 4.5.3 (2026-03-11 ucrt)
Platform: x86_64-w64-mingw32/x64
Running under: Windows 11 x64 (build 26200)

Matrix products: default
  LAPACK version 3.12.1

locale:
[1] LC_COLLATE=English_United Kingdom.utf8
[2] LC_CTYPE=English_United Kingdom.utf8
[3] LC_MONETARY=English_United Kingdom.utf8
[4] LC_NUMERIC=C
[5] LC_TIME=English_United Kingdom.utf8

time zone: America/Sao_Paulo
tzcode source: internal

attached base packages:
[1] stats     graphics  grDevices utils     datasets  methods   base

other attached packages:
 [1] gtExtras_0.6.2          ggiraph_0.9.6           scico_1.5.0
 [4] bayesplot_1.15.0        rstan_2.36.0.9000       StanHeaders_2.36.0.9000
 [7] mortalityAdherence_0.1.0 kableExtra_1.4.0       patchwork_1.3.2
[10] gt_1.3.0                scales_1.4.0            lubridate_1.9.5
[13] forcats_1.0.1           stringr_1.6.0           dplyr_1.2.1
[16] purrr_1.2.2             readr_2.2.0             tidyr_1.3.2
[19] tibble_3.3.1            ggplot2_4.0.3           tidyverse_2.0.0

loaded via a namespace (and not attached):
 [1] tidyselect_1.2.1       viridisLite_0.4.3      farver_2.1.2
 [4] loo_2.9.0              S7_0.2.2               fastmap_1.2.0
 [7] tensorA_0.36.2.1       fontquiver_0.2.1       digest_0.6.39
[10] timechange_0.4.0       lifecycle_1.0.5        posterior_1.7.0
[13] magrittr_2.0.5         compiler_4.5.3         sass_0.4.10
[16] rlang_1.2.0            tools_4.5.3            yaml_2.3.12
[19] knitr_1.51             labeling_0.4.3         htmlwidgets_1.6.4
[22] pkgbuild_1.4.8         curl_7.1.0             plyr_1.8.9
[25] xml2_1.5.2             RColorBrewer_1.1-3     abind_1.4-8
[28] withr_3.0.2            grid_4.5.3             stats4_4.5.3
[31] gdtools_0.5.1          inline_0.3.21          paletteer_1.7.0
[34] MASS_7.3-65            dichromat_2.0-0.1      cli_3.6.6
[37] rmarkdown_2.31         ragg_1.5.2             generics_0.1.4
[40] otel_0.2.0             RcppParallel_5.1.11-2  rstudioapi_0.18.0
[43] reshape2_1.4.5         tzdb_0.5.0             commonmark_2.0.0
[46] parallel_4.5.3         base64enc_0.1-6        matrixStats_1.5.0
[49] vctrs_0.7.3            V8_8.2.0               jsonlite_2.0.0
[52] fontBitstreamVera_0.1.1 carData_3.0-6         litedown_0.9
[55] car_3.1-5              hms_1.1.4              Formula_1.2-5
[58] systemfonts_1.3.2      fontawesome_0.5.3      glue_1.8.1
[61] rematch2_2.1.2         codetools_0.2-20       distributional_0.7.0
[64] stringi_1.8.7          gtable_0.3.6           QuickJSR_1.10.0
[67] sfsmisc_1.1-24         pillar_1.11.1          htmltools_0.5.9
[70] R6_2.6.1               textshaping_1.0.5      evaluate_1.0.5
[73] markdown_2.0           backports_1.5.1        fontLiberation_0.1.0
[76] Rcpp_1.1.1-1.1         checkmate_2.3.4        svglite_2.2.2
[79] gridExtra_2.3          xfun_0.58              fs_2.1.0
[82] pkgconfig_2.0.3
```

Referências

ABRAPP. **Consolidado Estatístico — Associação Brasileira das Entidades Fechadas de Previdência Complementar**. https://www.abrapp.org.br, 2022.

BÜHLMANN, Hans; GISLER, Alois. **A Course in Credibility Theory and Its Applications**. Berlin: Springer, 2005.

FENAPREVI. **Tábua BR-EMSsb-m v.2021 — Experiência do Mercado Segurador Brasileiro**. São PauloFederação Nacional de Previdência Privada e Vida, 2021.

GELMAN, Andrew *et al.* **Bayesian Data Analysis**. 3. ed. Boca Raton, FL: CRC Press, 2014.

KLUGMAN, Stuart A.; PANJER, Harry H.; WILLMOT, Gordon E. **Loss Models: From Data to Decisions**. 4. ed. Hoboken, NJ: John Wiley & Sons, 2012.

LORD, Dominique; MIRANDA-MORENO, Luis F. Effects of low sample mean values and small sample size on the estimation of the fixed dispersion parameter of Poisson-gamma models for modeling motor vehicle crashes: a Bayesian perspective. **Safety Science**, v. 46, p. 751–770, 2008.

MELO, Eduardo Fraga L. de; GRAZIADEI, Helton; TARGINO, Rodrigo. **mortalityAdherence: Mortality Table Adherence Tests**. R package, GitHub: https://github.com/eduardoflm/mortalityAdherence, 2026.

PITACCO, Ermanno *et al.* **Modelling Longevity Dynamics for Pensions and Annuity Business**. Oxford: Oxford University Press, 2009.

PREVIC. **Portaria PREVIC nº 835, de 3 de setembro de 2020**. Superintendência Nacional de Previdência Complementar, 2020.

RAU, Roland *et al.* Visualizing Mortality Dynamics in the Lexis Diagram. Cham: Springer, 2018.

SOCIETY OF ACTUARIES. **The 2000 Mortality Table**. Schaumburg, IL: Society of Actuaries, 2000.